淡江大學資訊工程學系碩士班

碩士論文

指導教授：陳建彰博士

以擴散模型潛在空間為基礎之多編碼器條件擴散強健浮水印方法

A Robust Watermarking Method Based on Multi-Encoder Conditional Latent Diffusion Models

研究生：林柏勳撰

中華民國 115 年 6 月

論文名稱:以擴散模型潛在空間為基礎之多編碼器條件擴散強健浮水印方法　　頁數:101

校系(所)組別：淡江大學資訊工程學系碩士班

畢業時間及提要別：114 學年度第 2 學期碩士學位論文提要

研究生：林柏勳　　指導教授：陳建彰博士

論文提要內容：

近年來，擴散模型在影像生成領域展現高度能力，使生成影像之來源追蹤與內容驗證成為重要議題。傳統像素空間浮水印方法在面對壓縮、雜訊與濾波等影像處理時，常需在影像品質與訊息強健性之間取得折衷；而潛在空間浮水印雖可降低訓練與生成成本，仍可能受固定參數 VAE 重建限制影響，造成最終 RGB 影像品質下降。

本文提出一套以潛在擴散模型為基礎之多編碼器條件擴散強健浮水印方法。本文方法使用 Stable Diffusion 2.1 之固定參數 VAE 進行 RGB 影像與潛在表示轉換，並設計潛在空間 U-Net 浮水印編碼器，將 32 位元二進位訊息嵌入潛在表示中。為提升多位元訊息表示能力，本文採用位元平面多尺度訊息注入，使各訊息位元於進入卷積層前保留通道識別性，並將多尺度訊息特徵注入 U-Net 不同解析度層級。

為改善 VAE 解碼後 RGB 影像品質，本文進一步加入 RGB 影像修復模組，並於

最終修訂階段採用 Dropout 感知式 RGB 修復訓練，以降低修復器過度偏向影像相似度而削弱浮水印訊號的問題。正式實驗結果顯示，本文最終校準設定可維持約 34 dB 之 PSNR、約 98.6%之非幾何攻擊平均 BA，且最低 BA 超過 90%。相較於原始 O256-RGB 基準版本，最終校準設定平均使最低 BA 提升 17.92 個百分點。整體而言，本文方法能在維持影像品質的同時，提升 32 位元浮水印訊息於非幾何攻擊下的恢復穩定性。

關鍵字:影像浮水印、潛在擴散模型、強健浮水印、潛在空間、位元平面訊息注入、RGB 影像修復、非幾何攻擊

＊依本校個人資料管理規範，本表單各項個人資料僅作為業務處理使用，並於保存期限屆滿後，逕行銷毀

表單編號：ATRX-Q03-001-FM030-03

Title of Thesis： Total pages:101

A Robust Watermarking Method Based on Multi-Encoder Conditional Latent Diffusion Models

Key word:

Image Watermarking , Latent Diffusion Model , Robust Watermarking , Latent Space , Bitplane Message Injection , RGB Refinement , non-geometric attack

Name of Institute:

Master’s Program, Department of Computer Science and Information Engineering, Tamkang University

Graduate date: Degree conferred: Master

June/2026

Name of student: PO-HSUN LIN Advisor: Dr. Chien-Chang Chen

林柏勳 陳建彰博士

Abstract:

In recent years, diffusion models have demonstrated strong image generation capabilities, making source tracing and content verification of generated images increasingly important. Conventional pixel-space watermarking methods often face a trade-off between image quality and robustness under compression, noise, and filtering attacks. Although latent-space watermarking can reduce training and generation costs, the reconstruction limitation of a frozen VAE may still degrade the final RGB image quality.

This thesis proposes a multi-encoder conditional diffusion-based robust watermarking method built upon latent diffusion models. The proposed method uses the frozen VAE of Stable Diffusion 2.1 to transform images between RGB and latent spaces, and designs a latent-space U-Net watermark encoder to embed a 32-bit binary message into the latent representation. To improve multi-bit message representation, bitplane multi-scale message injection is adopted, allowing each message bit to preserve channel-wise distinguishability before entering convolutional layers and injecting multi-scale message features into different resolution levels of the U-Net.

To improve the RGB image quality after VAE decoding, an RGB refinement module is further introduced. In the final revision stage, dropout-aware RGB refinement training is applied to reduce the tendency of the refiner to overemphasize image similarity while weakening watermark signals. Experimental results show that the final calibrated setting achieves approximately 34 dB PSNR, about 98.6% average bit accuracy under non-

geometric attacks, and a minimum bit accuracy above 90%. Compared with the original O256-RGB baseline, the final calibrated setting improves the minimum bit accuracy by 17.92 percentage points. Overall, the proposed method improves the recovery stability of 32-bit watermark messages under non-geometric attacks while maintaining image quality.

Keywords: image watermarking, latent diffusion model, robust watermarking, latent space, bitplane message injection, RGB refinement, non-geometric attack

According to “TKU Personal Information Management Policy Declaration“, the personal information collected on this form is limited to this application only. This form will be destroyed directly over the deadline of reservations.

表單編號：ATRX-Q03-001-FM031-03

目錄

第一章 緒論 1

1.1 研究背景與動機 1

1.2 研究目的 3

1.3 論文架構 4

第二章 背景技術與相關研究 6

2.1 數位影像浮水印之基本概念與評估觀點 6

2.2 擴散模型與潛在擴散模型之技術脈絡 8

2.2.1 由 GAN 至 Score-Based 生成 9

2.2.2 DDPM：離散時間擴散模型的建立 9

2.2.3 DDIM 與後續延伸 11

2.3 潛在擴散浮水印方法 15

2.3.1 後處理式與生成整合式浮水印 17

2.3.2 初始噪聲式方法 17

2.3.3 解碼器與微調式方法 18

2.3.4 潛在特徵與外掛式方法 19

2.3.5 條件擴散式方法 20

2.4 生成式攻擊與研究挑戰 22

2.5 本研究定位與小結 25

第三章 研究方法 28

3.1 整體架構與任務定義 29

3.2 三階段浮水印嵌入、修復與恢復流程 32

3.2.1 潛在空間浮水印嵌入 32

3.2.2 RGB 影像修復 40

3.2.3 訊息恢復與攻擊分支 43

3.3 訓練目標與版本設定 46

3.3.1 潛在浮水印基礎模型之訓練目標 47

3.3.2 RGB 影像修復模組之訓練目標 52

3.3.3 訓練版本與模型設定 55

第四章 實驗結果與分析 59

4.1 實驗設定 59

4.2 整體性能比較 66

4.3 非幾何攻擊強健性分析 72

4.4 消融實驗與方法設計分析 76

4.5 計算成本與推論效率分析 80

4.6 本章小結 86

第五章 結論與未來展望 90

5.1 研究結論 90

5.2 研究限制 93

5.3 未來展望 96

參考文獻 98

圖目錄

圖 1、DDPM 流程示意圖(引自 Ho 等人[1])..... 11

圖 2、LDM 基本架構示意圖(引自 Rombach 等人[2]）..... 14

圖 3、潛在擴散浮水印方法之分類架構（引自 Hur 等人[4]）..... 16

圖 4、DiffW 架構示意圖（引自 Luo 等人[6]）..... 21

圖 5、擴散式浮水印方法之主要攻擊類型示意圖 23

圖 6、本文方法之整體架構 30

圖 7、位元平面訊息表示與多尺度訊息注入流程 37

圖 8、階段一之潛在空間浮水印嵌入流程 38

圖 9、階段二之 RGB 影像修復流程..... 42

圖 10、階段三之訊息恢復與攻擊分支流程 45

圖 11、基礎模型與 RGB 影像修復模組之訓練目標流程..... 47

圖 12、原始 O256-RGB 基準版本之定性影像比較 71

表目錄

表 1、本文主要訓練版本與模型設定 57

表 2、實驗設定摘要 61

表 3、本章主要比較方法與實驗定位 63

表 4、正式測試集上之整體性能比較 67

表 5、原始 O256-RGB 基準版本與最終校準設定之整體差異 69

表 6、非幾何攻擊下之位元準確率比較 73

表 7、早期 RGB 影像修復分階段消融實驗結果 77

表 8、Dropout 感知式 RGB 修復訓練排程之設計演進 78

表 9、DiffW-like 與最終校準設定之訓練成本可比性檢查 82

表 10、本文最終校準設定之完整準備成本 83

表 11、locked finaltest1000 上之端到端推論時間比較 85

第一章 緒論

1.1 研究背景與動機

隨著生成式人工智慧技術快速發展，影像生成、編輯與再製的門檻大幅下降，擴散模型與潛在擴散模型也逐漸成為高品質影像生成的重要主流架構[1, 2]。相較於早期生成模型在訓練穩定性與生成品質上的限制，擴散模型在影像合成、編修與條件控制等任務中展現出更高的穩定性與實用性，使生成內容的真實性、來源性與可追溯性問題日益受到重視。

在此背景下，數位影像浮水印不再只是傳統意義下的版權保護工具，也逐漸成為辨識生成內容與建立來源追蹤機制的重要技術。對於一般數位影像而言，浮水印的主要目標在於在不明顯破壞影像視覺品質的前提下，嵌入可被後續檢測或解碼的訊息，使其在壓縮、裁切、模糊、加噪或其他常見影像處理後，仍保有一定程度的可恢復性。然而，當生成模型本身已可直接參與影像重建、再生成與語意導向編修時，僅依賴傳統像素層級訊號的浮水印設計，便可能面臨更高的失效風險[3]。

相較於傳統多在像素空間中進行訊息嵌入的方法，潛在擴散模

型的發展使浮水印的嵌入位置與設計方式出現新的可能。由於潛在空間具有較高的運算效率與較抽象的語義表示能力，若浮水印能夠在潛在表示中被有效建構與控制，則理論上有機會在維持生成品質的同時，兼顧訊號隱蔽性與後續恢復能力[2]。此外，近年相關研究也顯示，擴散式浮水印方法可依嵌入位置與模型介入方式形成不同技術路線，包括初始噪聲、解碼器、潛在特徵與條件控制等方向[4]。這也說明浮水印不再只是後處理式的附加訊號，而逐漸成為生成流程內部可被設計與控制的一部分。

然而，現有方法在隱蔽性、強健性、訓練成本與部署方式上仍存在明顯差異。尤其在生成式攻擊逐漸成熟之後，若浮水印僅停留於輸出影像表層，便可能在重建或再生成過程中遭到削弱甚至移除。另一方面，若浮水印能更深入地與生成過程或潛在表示結合，則有機會在對抗此類攻擊時保有較高韌性[5]。因此，如何在潛在空間中設計兼顧隱蔽性、強健性與可恢復性的浮水印方法，已成為一項值得深入探討的研究問題。

基於上述背景，本研究以擴散模型潛在空間為基礎，並以多編碼器條件擴散式浮水印方法作為重要研究脈絡，探討強健影像浮水印在潛在表示中進行嵌入、傳遞與恢復的可行性。此類方法顯示，

浮水印訊號可不再侷限於輸出影像表層，而能與生成條件、潛在表示或模型內部流程產生更深層的關聯。本文在此脈絡下，進一步聚焦於 32 位元訊息在潛在空間中的表示方式，並透過位元平面訊息表示與多尺度訊息注入，使二進位訊息能以較穩定的條件特徵形式注入潛在空間模型，進而分析影像品質、訊息可恢復性與非幾何攻擊強健性之間的折衷關係[2, 6]。

1.2 研究目的

基於前述研究背景與動機，本研究旨在探討以擴散模型潛在空間為基礎之強健影像浮水印方法，並以多編碼器條件擴散式浮水印研究作為主要參照脈絡，分析其在現代擴散式浮水印方法中的可行性與限制。相較於僅在像素空間中進行訊息嵌入的傳統方法，潛在空間具有較高的運算效率與較抽象的特徵表示能力；而條件式訊息注入設計則提供了將浮水印訊號納入模型內部特徵流程的研究方向。因此，本文聚焦於 32 位元訊息於 Stable Diffusion 2.1 VAE 潛在空間中的表示、嵌入與恢復，並進一步分析 RGB 影像修復模組對影像品質與訊息保留能力之影響[2, 6]。此外，本文亦關注 RGB 修復過程可能削弱浮水印訊號的問題，並透過 Dropout 感知式 RGB 修復訓練排程，使修復器在改善影像品質的同時，保留攻擊後仍可

被訊息解碼器恢復的浮水印訊號。

在此基礎上，本研究希望建立一套以潛在空間為核心之浮水印嵌入方法，探討浮水印訊號在原始潛在表示中的嵌入、傳遞與恢復是否可行。同時，本文亦將透過文獻整理與方法比較，釐清本研究方法在現有擴散式浮水印技術中的定位，並進一步分析其在生成式攻擊與常見影像處理操作下的表現，作為後續研究方法設計與實驗驗證的依據[4]，至於生成式攻擊與影像編輯情境，則作為本文研究限制與未來延伸方向進行討論。

1.3 論文架構

本論文共分為五章，各章內容概述如下。

第一章為緒論，主要說明本研究之背景、研究動機、研究目的與整體論文架構，並交代本研究為何聚焦於潛在空間、條件式擴散浮水印研究脈絡以及強健浮水印方法之設計。

第二章為背景技術與相關研究，將回顧擴散模型與潛在擴散模型之基本原理，整理數位影像浮水印與擴散式浮水印之研究發展，並進一步說明現有方法在初始噪聲、解碼器、潛在空間、擴散過程與完整模型優化等面向上的分類方式。

第三章為研究方法，將詳細說明本文以潛在空間為核心之強健影像浮水印方法，包括整體架構設計、潛在空間表示、位元平面訊息表示、多尺度訊息注入、RGB 影像修復模組與對應之訓練流程，並說明其與既有條件式擴散浮水印方法之差異。

第四章為實驗結果與分析，將針對本研究方法之影像品質、訊息恢復能力、非幾何攻擊強健性與計算成本進行分析，並比較 DiffW-like、O256-Base、原始 O256-RGB 基準版本與最終校準設定於正式測試集上的表現。此外，本章亦進一步討論 Dropout 攻擊下的最低 BA、RGB 修復設計演進、分階段消融實驗，以及端到端推論效率。

第五章為結論與未來展望，將總結本研究之主要發現，說明本研究於潛在空間擴散式浮水印領域中的定位，並進一步提出後續在浮水印注入位置、訊號穩健性、解碼可靠性與生成式攻擊防禦方向上的可能延伸。

第二章 背景技術與相關研究

本章整理本研究所需之背景技術與相關文獻，作為後續方法設計與實驗分析之基礎。首先說明數位影像浮水印的基本概念、核心需求與常見評估觀點；接著回顧生成模型由 score-based 方法發展至 DDPM、DDIM、連續時間 SDE 統一觀點，以及進一步延伸至潛在空間擴散與條件控制的技術脈絡；最後整理基於擴散模型與潛在擴散模型之浮水印方法，並討論生成式攻擊情境下的脆弱性與研究挑戰，以作為第三章研究方法與第四章實驗分析的理論基礎。

2.1 數位影像浮水印之基本概念與評估觀點

數位影像浮水印係指在不明顯影響原始影像視覺品質的前提下，將特定訊息嵌入影像中，使該訊息可於後續被偵測、驗證或解碼，以達成版權保護、來源追蹤、內容識別與責任歸屬等目的。依據呈現方式的不同，浮水印可大致分為可見浮水印與不可見浮水印。前者通常直接顯示於影像表面，主要用於宣示版權；後者則將訊息隱藏於影像中，不直接干擾觀看體驗，因此更常被應用於版權保護與來源驗證等情境。

在生成式模型快速發展的背景下，數位影像浮水印的重要性進

一步提升。尤其當高品質影像可由擴散模型與潛在擴散模型大規模生成時，如何辨識生成內容並建立來源追蹤機制，已成為內容治理與版權保護的重要議題[2]。因此，浮水印不再只是附加於影像中的保護訊號，也逐漸成為生成內容識別與可追溯性的技術基礎。

一般而言，一個有效的數位影像浮水印方法通常需同時考量數項核心要求。首先為隱蔽性，即嵌入後的影像應盡量維持原有視覺品質，避免因訊號植入而產生明顯失真。其次為強健性，亦即當影像經過壓縮、裁切、模糊、加噪或其他常見影像處理後，浮水印仍具有一定程度之可恢復性。再者為容量，即單張影像可攜帶多少有效訊息；在需支援多使用者或多金鑰識別的場景中，此一因素亦與後續應用需求密切相關。此外，在生成式內容情境下，浮水印方法也常需進一步考量可追溯性與可歸屬性，也就是不僅要判斷影像是否由模型生成，還需能在必要時辨識其對應之來源模型、帳號或使用者。

在評估方式上，相關研究通常會從影像品質與訊號恢復兩個主要面向進行分析。在影像品質方面，常見指標包括峰值訊噪比、結構相似度、學習式感知距離與 Fréchet Inception Distance；在訊號恢復與識別方面，則常以位元準確率、真陽性率、偽陽性率或識別準

確率作為主要衡量依據，用以觀察嵌入訊息是否能在攻擊後被正確還原，或是否能準確判定其對應來源。

由於不同方法在畫質、強健性、容量與訓練成本之間往往存在取捨，因此在比較各類方法時，不能僅依賴單一指標判定優劣，而仍需綜合考量影像品質、訊號恢復能力與實際部署情境，才能較完整地評估其適用性。對本研究而言，先釐清數位影像浮水印的基本概念與評估觀點，有助於建立後續擴散式浮水印方法分析與實驗設計的比較基礎。

2.2 擴散模型與潛在擴散模型之技術脈絡

在進一步討論潛在擴散浮水印方法之前，必須先釐清擴散模型本身的技術演進。現有多數相關方法雖皆建立於擴散模型架構之上，但其背後所依賴的生成機制並不完全相同，從早期的 score-based 觀點、離散時間的 DDPM、強調高效率與可逆性的 DDIM，到連續時間的 SDE 統一框架，以及後續潛在空間的 LDM，彼此之間具有承接關係而非彼此獨立。本節將依此脈絡整理各階段的核心概念與主要改良方向，作為後續分析浮水印嵌入位置與方法分類的基礎。

2.2.1 由 GAN 至 Score-Based 生成

在擴散模型普及之前，生成對抗網路曾長期被視為高品質影像生成的重要代表架構。然而，GAN 雖能生成具高度視覺逼真性的影像，卻也經常面臨訓練不穩定、模式崩潰與難以完整描述資料分布等問題。為了尋求更穩定且更具理論一致性的替代方案，研究者逐漸轉向另一種思路，也就是不直接建模資料分布本身，而改以估計資料分布對數密度的梯度，亦即分數函數，作為生成過程的基礎[7]。

在此觀點下，模型不再以對抗訓練方式直接學習生成器與判別器之間的博弈關係，而是透過對不同噪聲層級下資料分布梯度的估計，逐步建立由噪聲回到資料分布的生成路徑。這樣的想法為後續擴散模型的建立提供了重要理論基礎，也使生成模型的發展逐漸由對抗式架構，轉向以加噪與去噪為核心的機率式生成框架。此一轉變，最終在離散時間擴散模型中被進一步具體化。

2.2.2 DDPM：離散時間擴散模型的建立

離散時間擴散模型可視為擴散模型走向主流的重要起點，其基本框架由正向加噪與反向去噪兩個過程所構成[1]。在正向過程中，

模型逐步向真實資料加入高斯雜訊，使資料最終趨近於標準高斯分布；在反向過程中，模型則學習逐步去除噪聲，從純噪聲還原出資料樣本。此一設計使生成流程具備清楚的機率詮釋，也讓訓練目標得以轉化為較穩定的噪聲預測問題。若以機率分布表示，DDPM 的正向加噪過程可寫為公式(1)：

$$q(x_t \mid x_{t-1}) = \mathcal{N}\left(x_t; \sqrt{1-\beta_t}\, x_{t-1}, \beta_t I\right) \tag{1}$$

其中，x_{t-1}表示前一時間步的樣本，x_t表示加入雜訊後的樣本，β_t為第t步的雜訊強度參數。此式表示 DDPM 在正向過程中，會逐步將原始資料推向高斯雜訊分布。進一步地，任意時間步的樣本亦可直接表示為原始資料與高斯雜訊的組合

如公式(2)所示：

$$q(x_t \mid x_0) = \mathcal{N}\left(x_t; \sqrt{\overline{\alpha_t}}\, x_0, (1-\overline{\alpha_t})I\right) \tag{2}$$

其中$\overline{\alpha_t}$為保留率的累積乘積。此式有助於理解擴散過程如何逐步破壞原始資料結構。

為了更清楚說明 DDPM 的生成流程，圖 1 示意其由正向加噪與反向去噪所構成的基本架構。

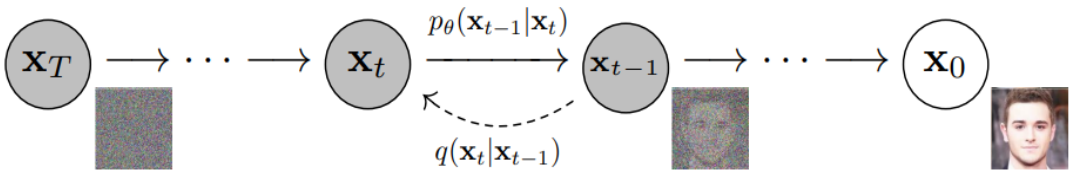


圖 1、DDPM 流程示意圖(引自 Ho 等人[1])

如圖 1 所示，DDPM 的核心在於先透過正向擴散逐步向資料加入高斯雜訊，使原始樣本最終趨近於標準高斯分布，再透過反向擴散學習由噪聲逐步還原資料。此一架構使生成流程具備清楚的機率詮釋，也讓模型得以透過噪聲預測方式完成訓練，成為後續擴散模型家族發展的重要起點。

相較於先前生成模型容易受到訓練不穩定與模式崩潰影響，DDPM 的重要性不僅在於樣本品質的提升，更在於它提供了一套可被明確分析與擴充的生成框架。也因為如此，後續許多研究並非脫離 DDPM 另起爐灶，而是在其基礎上，分別朝取樣效率、理論統一、條件控制與架構壓縮等方向延伸。換言之，DDPM 不只是擴散模型的代表性方法，也可視為後續多數擴散模型相關研究的共同起點。

2.2.3 DDIM 與後續延伸

雖然 DDPM 在樣本品質與訓練穩定性上具有優勢，但其生成

過程通常需經過大量去噪步驟，導致取樣成本較高，難以直接應用於高效率生成與可操作性需求較強的任務。為解決此一問題，Song等人提出 DDIM[8]，使模型在不改變原始訓練目標的情況下，仍能以較少步數完成高品質取樣。此一方法的關鍵在於，DDIM 保留與 DDPM 相同的訓練目標與邊際分布，但允許在推論時採取更具彈性且更有效率的取樣路徑，若以較具決定性的更新形式表示 DDIM 的反向取樣可簡化寫為式(3)：

$$x_{t-1} = \sqrt{\overline{\alpha_{t-1}}}\,\widehat{x_0} + \sqrt{1-\overline{\alpha_{t-1}}}\,\epsilon_\theta(x_t, t) \tag{3}$$

此式表示 DDIM 可在較少步數下完成影像還原，並透過較低的隨機性使生成結果與潛在表示之間的映射關係更加穩定。也因此，DDIM 不僅提升了取樣效率，也為後續反演與編修操作提供了更具可行性的基礎。

DDIM 的另一項重要意義在於其較強的可逆性。當取樣路徑採用較具決定性的設定時，模型對於潛在表示與生成結果之間的映射關係會更加穩定，進而使反演成為可能。因此，DDIM 不只是加速版的擴散取樣方法，它同時也是後續生成式追蹤與浮水印方法的重要技術基礎[8]。

在 DDPM 與 DDIM 建立離散時間擴散模型的基本輪廓後，後續研究也逐漸從更高層次整理擴散模型家族的理論關係。YangSong 等人提出 SBGM[9]，並從連續時間角度將先前的 score-based 模型與擴散機率模型整合到更一般化的 SDE/ODE 框架中。此一架構的重要性，不在於單純提出另一種全新模型，而在於它提供了一個更高層次的統一視角，使先前離散時間擴散模型的多種變體能在同一數學架構下被理解與比較。

另一方面，當擴散模型的基本框架逐漸成熟後，研究焦點也由是否可行轉向是否能在品質上全面與既有最佳生成模型競爭。Dhariwal 等人透過架構改良與分類器引導機制的設計，進一步提升了擴散模型在影像生成任務中的品質表現[10]，並顯示其在視覺品質上可超越當時多數 GAN 方法。這一發展的重要性，不僅在於生成品質的提升，也在於它顯示生成流程可以被更細緻地控制，進而為後續將浮水印視為條件訊號的設計提供技術基礎。

儘管擴散模型已逐漸展現優秀的生成能力，但若直接在高解析影像的像素空間中進行多步擴散與去噪，計算成本仍然相當高。因此，Rombach 等人提出 LDM[2]，進一步將擴散過程轉移至潛在空間進行，先以 VAE 將影像壓縮為低維潛在表示，再於潛在空間中

執行擴散與去噪，最後透過解碼器還原成影像。此一設計在維持高影像品質的同時，大幅降低了記憶體與運算負擔，也使後續浮水印不再必須侷限於輸出影像表層，而可進一步考慮在潛在表示中進行設計與控制。

為了說明潛在擴散模型如何將擴散過程由像素空間轉移至潛在空間，圖 2 示意 LDM 的基本架構。

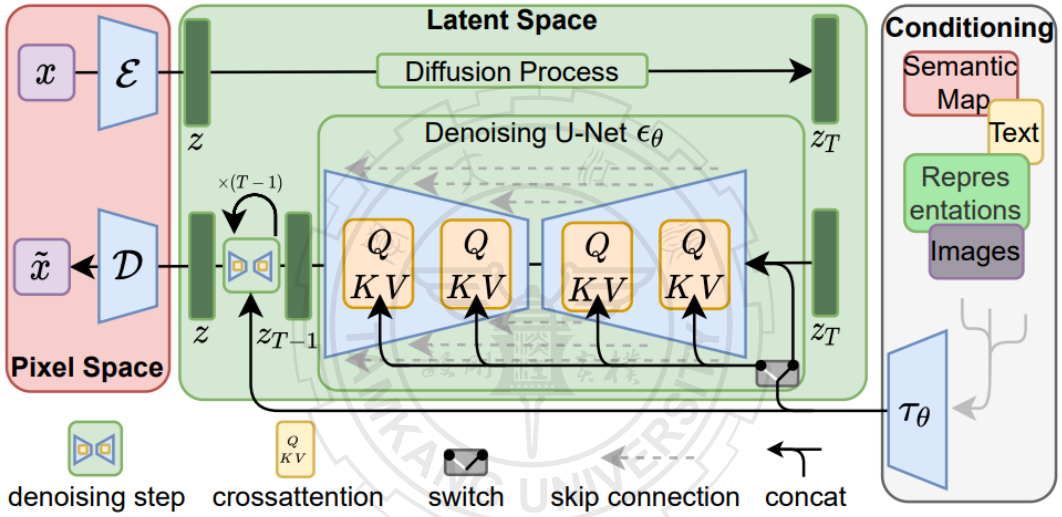


圖 2、LDM 基本架構示意圖(引自 Rombach 等人[2])

如圖 2 所示，LDM 先透過 VAE 編碼器將影像壓縮至低維潛在表示，再於潛在空間中執行擴散與去噪，最後由解碼器還原為最終影像。相較於直接在高解析度像素空間中進行擴散，LDM 能有效降低記憶體與運算負擔，同時保留高品質生成能力。此一設計也使浮水印的嵌入位置不再侷限於輸出影像表層，而能進一步延伸至潛

在表示與生成流程內部，這也是本研究聚焦於潛在空間的主要原因之一。

綜合而言，DDIM 之後的相關發展並不是脫離 DDPM 的另一條全新方法線，而是沿著擴散模型架構持續往效率、理論統一、條件控制與潛在空間壓縮等方向延伸。對本研究而言，這些後續發展之所以重要，正在於它們共同構成了潛在擴散浮水印方法得以成立的技術背景：一方面提供更穩定且可逆的生成表示，另一方面也讓浮水印得以在潛在空間、條件訊號與生成流程內部被更細緻地設計與控制。

2.3 潛在擴散浮水印方法

隨著潛在擴散模型逐漸成為高品質影像生成的重要主流，數位浮水印方法的設計空間也隨之擴大。相較於傳統方法多在像素空間中進行後處理式嵌入，Hur 等人在綜述中提出潛在擴散模型相關方法已逐步延伸至初始噪聲、解碼器、潛在特徵、外掛模組以及條件式生成流程等多種位置[4]。因此，本節將依其技術路線，整理現有潛在擴散浮水印方法的主要類型。為了更清楚呈現潛在擴散浮水印方法的主要分類脈絡，圖 3 引用 Hur 等人綜述中所整理的分類架構。

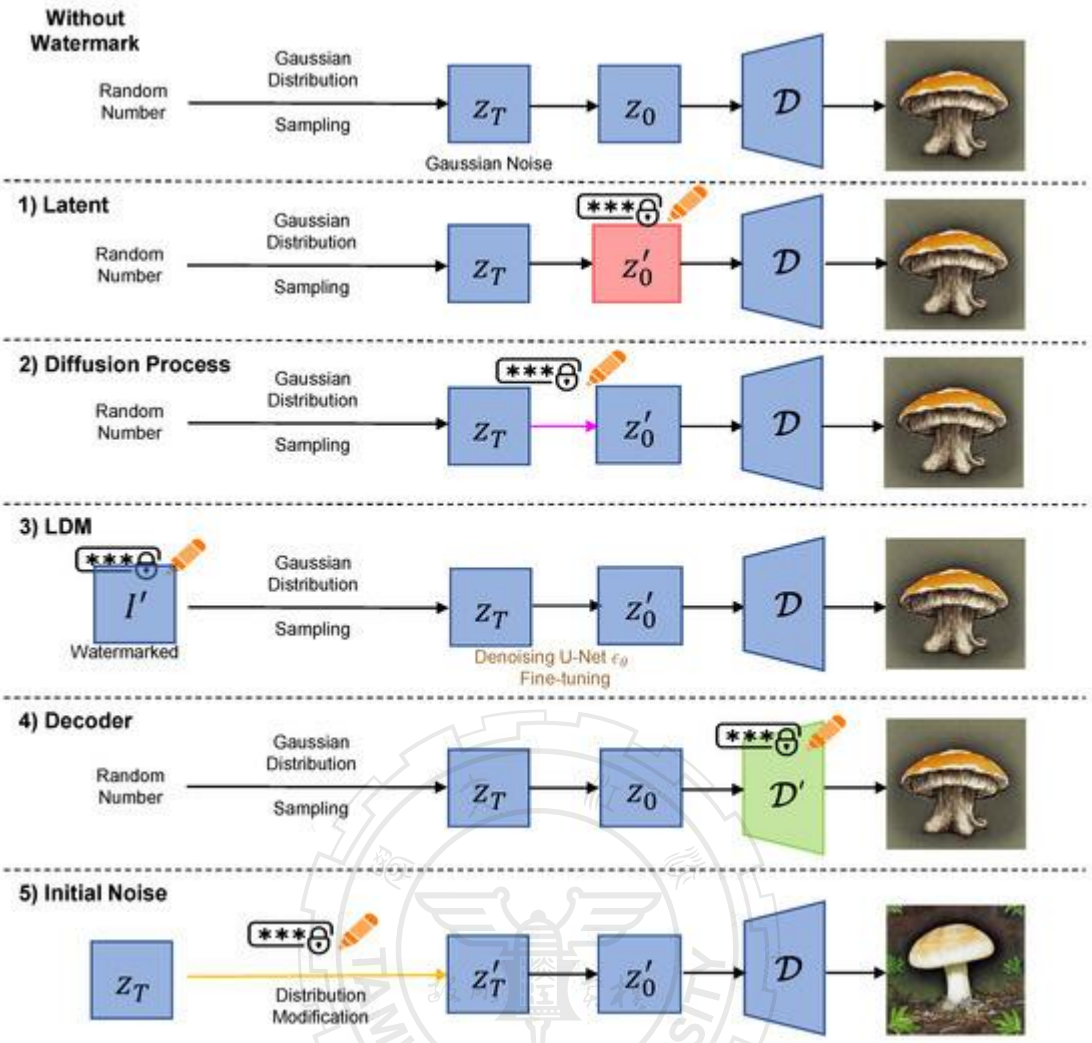


圖 3、潛在擴散浮水印方法之分類架構（引自 Hur 等人[4]）

如圖 3 所示，Hur 等人將潛在擴散浮水印方法依嵌入位置與模型介入方式加以分類。本文參考此一整理脈絡，並結合本研究在方法論上的分析需求，先將相關方法概略區分為後處理式與生成整合式兩大方向，再進一步依其實際嵌入位置與控制方式，整理為初始噪聲式、解碼器與微調式、潛在特徵與外掛式，以及條件擴散式等技術路線。藉由此一安排，可更清楚說明各類方法在生成流程中的

介入位置，以及其與本研究方法之關聯。

2.3.1 後處理式與生成整合式浮水印

從整體方法論來看，相關方法可先概略區分為後處理式與生成整合式兩大方向。後處理式方法係指在影像生成完成後，再透過額外的浮水印編碼器或訊號嵌入程序，將訊息植入最終影像中；此類方法可與生成模型本身解耦，但其訊號通常停留於像素層級，因此在面對重建、再生成或語意編修時，較容易受到破壞[3]。相對地，生成整合式方法則嘗試將浮水印直接嵌入生成流程本身，使訊號更深入地與噪聲、潛在表示、模型參數或條件控制機制結合。

在潛在擴散模型的研究脈絡中，生成整合式方法逐漸成為主要方向，其原因在於此類方法更有機會兼顧隱蔽性、生成品質與對生成式攻擊的抵抗能力。不過，所謂生成整合並不代表所有方法都採取相同策略，後續仍可依其實際嵌入位置與控制方式，再進一步區分為不同技術路線。

2.3.2 初始噪聲式方法

初始噪聲式方法的基本概念，是在擴散生成開始之前，先於噪聲端植入特定訊號，使該訊號能隨著後續去噪過程隱性地反映於最

終生成結果中。這一路線的重要代表為初始噪聲圖樣的設計方式，其典型研究顯示，浮水印可被嵌入噪聲空間，並在後續檢測時透過反演回推後完成辨識[11]。這種做法的重要意義，在於它不依賴傳統的 post-hoc 像素擾動，而是將浮水印視為生成分布的一部分。

在此基礎上，部分研究進一步朝高容量或高穩定性方向延伸。例如，有些方法著重提升可攜帶的訊息量，以支援更多使用者識別需求；另一些方法則強調在盡量不破壞原有生成品質與分布的前提下，完成浮水印的植入與檢測[12, 13]。整體而言，初始噪聲式方法的主要優勢在於不需大幅改動既有生成模型，但其檢測往往高度依賴反演或噪聲重建程序，因此在攻擊下的穩定性仍與回推品質密切相關。

2.3.3 解碼器與微調式方法

另一類重要方法，係透過微調潛在擴散模型的部分參數，使模型生成結果天然帶有指定浮水印。此一路線的代表作之一為 StableSignature[14]，其先訓練訊息編碼／解碼模組，再透過微調潛在解碼器，使該解碼器所生成之影像能隱含固定簽章訊息[14]。這種做法的優點，在於浮水印被直接植入模型參數之中，使用者在生成影像時無需額外執行後處理模組，因而較適合開源擴散模型的使

用情境。不過，相對限制也在於其浮水印通常與特定解碼器綁定，若需支援多種訊息或多使用者場景，便可能面臨擴展性不足的問題。

後續研究則進一步探索更具追溯性與效率性的微調方式。部分方法透過對模型權重進行調制，使不同使用者可對應不同指紋；另一些方法則嘗試在浮水印注入與檢測之間建立更一致的訓練架構，以兼顧高追溯性與實務可用性[15, 16]。此外，也有研究引入參數效率微調觀念，以降低浮水印植入所需的訓練成本[17]。因此，解碼器與微調式方法的核心特色，在於利用模型內部參數承載浮水印，但其代價通常是較高的維護成本與較強的模型綁定性。

2.3.4 潛在特徵與外掛式方法

相較於直接修改整個模型或僅專注於初始噪聲，另一條逐漸受到重視的路線是將浮水印植入潛在特徵本身，或透過外掛式模組在潛在擴散流程中動態控制浮水印訊號。此類方法的重要特徵，在於它們保留原有生成架構的大部分能力，同時透過額外模組提升浮水印的靈活性與可控制性。代表性的研究方向顯示，浮水印控制不一定必須完全根植於原模型權重，也可以透過附加模組的方式插入既有 LDM 流程[18]。

此外，也有方法更強調潛在空間本身的嵌入與檢測能力。其核心觀點在於，若浮水印能同時在潛在擴散模型中完成注入與檢測，便有機會降低對像素擾動的依賴，並進一步緩解影像品質與強健性之間的衝突[19]。另一些方法則利用潛在擴散與 DDIM 反演結合來提升攻擊韌性，或藉由展頻技術等設計加強浮水印在再生與編修情境下的保存能力[5, 20]。整體而言，此一路線的重點，在於利用潛在表示本身作為浮水印的主要操作空間。

2.3.5 條件擴散式方法

除了噪聲、解碼器與潛在特徵等嵌入路線之外，另一類值得關注的方法，是將浮水印視為生成過程中的條件訊號，直接整合進條件擴散模型架構。此類方法的重要意義，在於浮水印不再只是靜態地植入某個模組，而是成為生成控制的一部分。其代表作顯示，透過將浮水印視為條件輸入，可使模型在生成過程中攜帶使用者特定指紋，並在後續完成浮水印偵測與影像所有者識別[21]。

在強健影像浮水印的研究脈絡中，多編碼器條件擴散設計則提供了另一條具有代表性的路線。這類方法強調浮水印與生成條件、生成過程以及訊號控制之間的互動關係，使浮水印分布不再只是由單一路徑決定，而能透過多編碼器結構逐步調整[6]。為了更具體說

明多編碼器條件擴散式浮水印方法的設計概念，圖 4 示意 DiffW 的代表性架構。

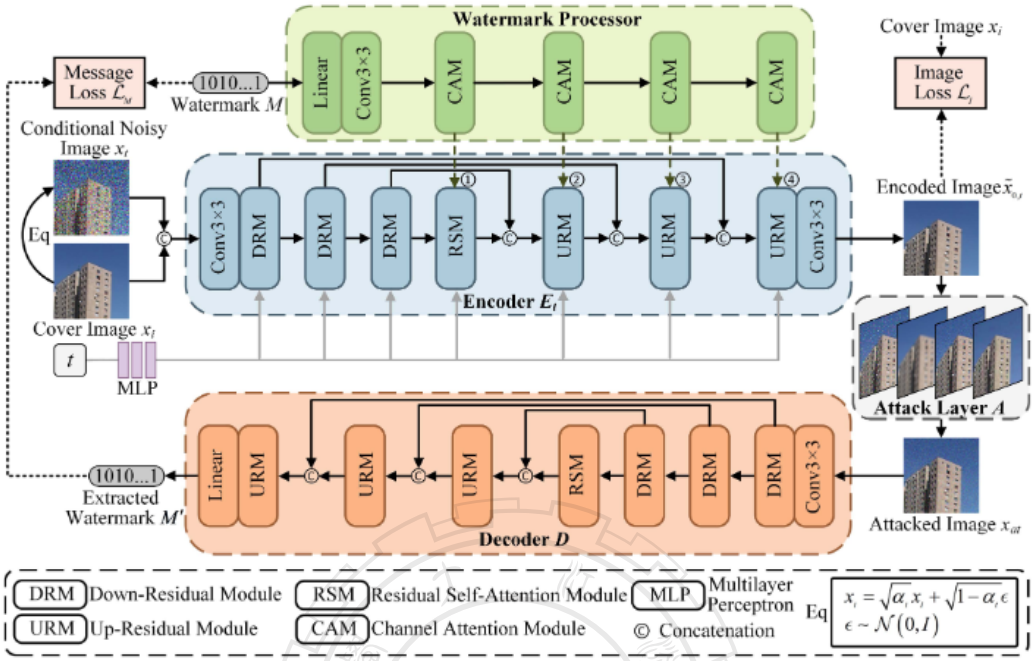


圖 4、DiffW 架構示意圖（引自 Luo 等人[6]）

如圖 4 所示，DiffW 將浮水印訊號與條件擴散流程結合，並透過多編碼器結構在不同模組或階段中逐步調整訊號分布，使浮水印不再只是單一路徑的附加資訊，而能更深入地參與生成控制。此類方法的重要性在於，它將浮水印視為生成條件的一部分，而非單純的後處理擾動，因此在強健性與可控制性上具有更高的發展潛力。

對本研究而言，此一路線特別重要，因為它與多編碼器設計、條件式生成以及浮水印可控制性之間具有直接關聯，也為後續研究

方法的設計提供了明確參照方向。本文並非直接重現 DiffW 原始方法或沿用其官方模型結果，而是在此研究脈絡下，進一步聚焦於 Stable Diffusion 2.1 VAE 潛在空間中的多位元訊息表示、位元平面多尺度訊息注入，以及 RGB 影像修復對輸出品質與訊息保留能力之影響。相關設計之成效則於第四章以正式實驗結果與補充設計分析進行討論。

2.4 生成式攻擊與研究挑戰

隨著擴散模型與潛在擴散模型逐漸被廣泛應用於影像生成、編修與再生成任務，浮水印方法所面對的威脅模型也不再侷限於傳統影像處理攻擊。早期浮水印研究多將攻擊視為壓縮、裁切、模糊、亮度調整或加性雜訊等訊號層級擾動，因此方法設計通常聚焦於如何在這類後處理操作下維持可恢復性。然而，當生成模型本身已可參與影像重建、去噪、再採樣與語意導向編修時，僅依賴像素層級訊號的浮水印設計，便可能面臨更高的失效風險[3]。

從攻擊形式來看，與擴散模型相關的浮水印威脅大致可分為三類。第一類為傳統破壞式攻擊，即對輸出影像施加壓縮、模糊、裁切、亮度調整或雜訊等操作，以測試浮水印的基本強健性。第二類為重建式攻擊，即利用擴散模型、自編碼器或其他生成模型，將輸

入影像映射至潛在表示後再重新生成，藉由重建過程中對原始訊號分布的重塑來削弱浮水印。第三類則可視為模型層級攻擊，也就是直接針對浮水印所依附的模型參數、解碼器或特定模組進行再訓練、微調或移除，使模型後續輸出的影像不再攜帶原先的浮水印[22]。

為了更清楚呈現擴散式浮水印方法所面對的主要威脅類型，圖 5 將相關攻擊整理為傳統破壞式攻擊、重建式攻擊與模型層級攻擊三類。

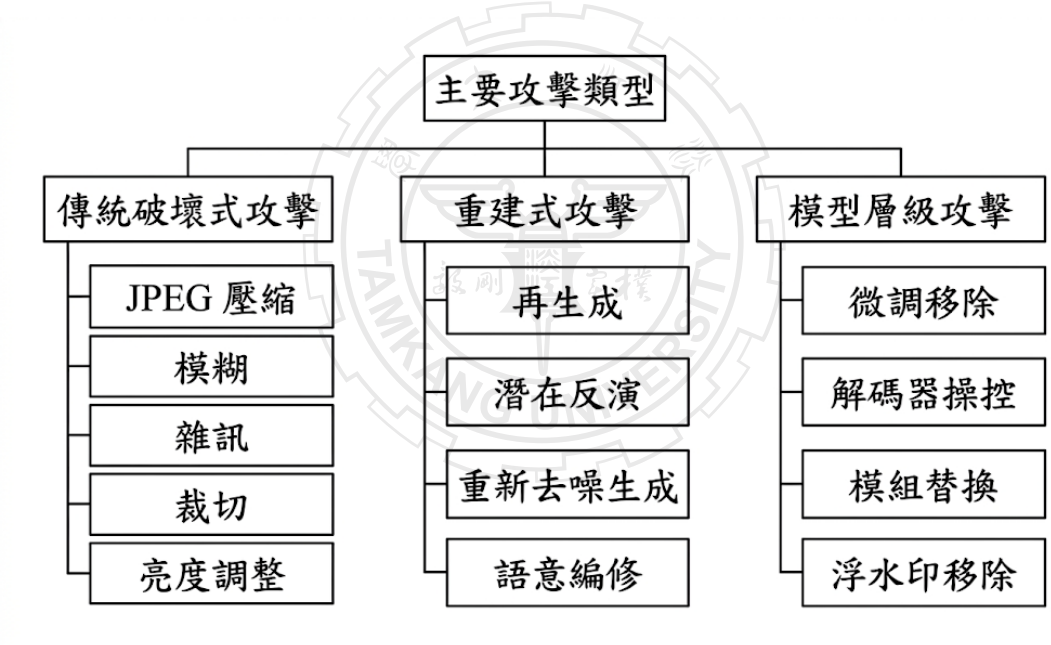


圖 5、擴散式浮水印方法之主要攻擊類型示意圖

如圖 5 所示，擴散式浮水印方法所面對的威脅已不再侷限於傳統影像處理操作，而是進一步延伸至生成式重建與模型層級移除等

情境。相較於單純的壓縮、模糊或加噪攻擊，後兩類攻擊更可能直接改變訊號所依附的生成表示或模型結構，因此也使現有浮水印方法在設計上必須同時考量畫質、強健性、可控性與部署成本之間的取捨。

在此背景下，現有研究逐漸轉向更深入地將浮水印與生成流程結合，而不再僅停留於輸出影像表層。其核心理由在於，若浮水印能與初始噪聲、潛在表示、解碼器權重或條件控制訊號建立更緊密的連結，理論上便更有機會在重建與再生成情境下維持其可檢測性。不過，這也帶來另一層挑戰：方法雖可能變得更穩健，卻也可能同時提高模型修改成本、訓練複雜度與部署門檻。

除了攻擊韌性之外，現有方法還面臨若干共通研究挑戰。首先是畫質與強健性的取捨問題。若浮水印訊號過弱，雖有助於維持影像品質，卻可能在攻擊下難以被可靠檢測；反之，若訊號過強，則可能造成生成結果失真。其次是擴展性與可控性問題。對於需支援多使用者、多金鑰或多訊息的場景而言，方法是否能在不重複完整訓練的前提下擴展至大量浮水印組合，是實際部署時的重要考量[21]。第三則是部署成本問題。若方法需對大型擴散模型進行完整微調，則在模型規模持續擴大的背景下，訓練成本與維護成本都可

能快速上升，因此外掛模組、低秩調整與局部微調等方向也逐漸受到重視[17, 18]。

綜合而言，擴散模型中的浮水印研究已由早期的訊號嵌入問題，逐步轉變為一個同時涉及生成流程設計、潛在表示控制、模型調整策略與攻擊防禦的綜合性問題。現有文獻雖已展示多條可行技術路線，但在面對生成式重建、語意編修與模型層級移除等威脅時，仍普遍存在畫質、強健性、擴展性與部署成本之間的取捨困難[4]。

2.5 本研究定位與小結

綜合本章所整理之背景技術與相關研究可知，擴散模型的發展使生成模型在品質、效率與可控性方面皆獲得顯著提升，而數位影像浮水印方法也由傳統後處理式嵌入，逐漸轉向與生成流程更緊密結合的方向[4]。在潛在擴散模型的研究脈絡下，浮水印的嵌入位置已不再侷限於輸出影像表層，而可延伸至初始噪聲、解碼器、潛在特徵與條件控制等不同層面，顯示潛在空間已成為此領域的重要研究核心。

然而，現有方法仍普遍面臨數項限制。部分方法高度依賴反演與噪聲回推，部分方法雖可使浮水印與模型深度整合，卻需付出較

高的訓練或維護成本；另一些方法雖在彈性上較具優勢，但其訊號穩定性與攻擊韌性仍有待更充分驗證[6]。此外，生成式重建、語意編修與模型層級移除等新型態攻擊，也使浮水印方法不能再只依賴傳統影像處理攻擊作為主要評估依據。

在此文獻脈絡下，本研究將焦點放在以潛在空間為基礎之條件式強健浮水印方法，並以多編碼器條件擴散浮水印研究作為重要參照。相較於僅依賴像素擾動或單一後處理模組的設計，本文關注的是如何在潛在表示中建立穩定的多位元訊息條件表示，使浮水印訊號能以較具結構性的形式參與潛在空間特徵調整，並在隱蔽性、可恢復性與攻擊韌性之間取得較佳折衷[2]。

此外，本文亦關注潛在空間浮水印經固定參數 VAE 解碼至 RGB 影像後所產生的品質落差。由於潛在表示中的浮水印訊號必須經由 VAE 解碼器轉換回像素空間，影像修復模組雖可改善最終輸出影像與原始影像之間的視覺差異，但也可能同時削弱對訊息解碼有用的浮水印訊號。因此，本文不僅討論浮水印訊息如何在潛在空間中嵌入與恢復，也進一步探討 RGB 影像修復過程中影像品質與訊息可恢復性之間的折衷關係。

因此，本章的整理不僅建立了本研究所需的理論背景，也進一

步說明了本文所欲處理的核心問題：在擴散模型與潛在擴散模型逐漸主導生成式影像技術的背景下，如何設計一種適合於潛在空間中運作，並能結合條件式訊息注入與多尺度訊息表示優勢的強健浮水印方法。基於此一定位，下一章將進一步說明本文所採用之方法架構、潛在空間訊息嵌入流程、RGB 影像修復模組與整體訓練設計，並具體描述各模組之功能、資料流與訓練排程之間的關係。

TAMKANG UNIVERSITY

第三章 研究方法

本章說明本研究所提出之潛在擴散影像浮水印方法。本文方法以潛在空間中的 32 位元二進位浮水印嵌入為核心，結合固定參數 Stable Diffusion 2.1 VAE、潛在空間 U-Net 浮水印編碼器、位元平面多尺度訊息注入、RGB 影像修復模組，以及訊息恢復分支，形成一套由潛在空間嵌入至 RGB 影像輸出，再由影像重新編碼回潛在空間進行訊息恢復的完整流程。

本文方法可分為三個主要階段。第一階段為潛在空間浮水印嵌入，負責將原始影像轉換為潛在表示，並將 32 位元訊息注入潛在空間 U-Net 浮水印編碼器，以產生含浮水印潛在表示與含浮水印 RGB 影像。第二階段為 RGB 影像修復，負責在 VAE 解碼器輸出後進行殘差式影像修復，以降低含浮水印 RGB 影像與原始影像之間的品質落差。第三階段為訊息恢復與攻擊分支，負責將修復後影像重新編碼至潛在空間，並透過共享權重之訊息解碼器恢復嵌入訊息，同時建立未受攻擊與非幾何攻擊條件下的訊息恢復路徑。

本章後續內容安排如下。第 3.1 節說明整體架構與任務定義，包含本文任務設定、輸入輸出、主要符號，以及圖 6 所示三階段流程之整體關係。第 3.2 節依據圖 6 將方法流程拆分為三個小節：第

3.2.1 節說明階段一之潛在空間浮水印嵌入流程，第 3.2.2 節說明階段二之 RGB 影像修復流程，第 3.2.3 節說明階段三之訊息恢復與攻擊分支流程；各小節將以對應之演算法輔助說明資料流與主要運算步驟。第 3.3 節則整理本文之訓練目標、損失函數與不同模型版本設定，並說明原始 O256-RGB 基準版本、Dropout 感知式 RGB 修復訓練排程與最終校準設定之間的關係。

3.1 整體架構與任務定義

本研究旨在給定一張原始影像的情況下，將 32 位元二進位訊息嵌入影像中，並產生兼具影像品質與訊息可恢復性的含浮水印影像。本文方法以固定參數 Stable Diffusion 2.1 VAE 作為影像與潛在表示之間的轉換基礎，並將主要可訓練模組分為潛在空間 U-Net 浮水印編碼器、RGB 影像修復模組與訊息解碼器三個部分。潛在空間 U-Net 浮水印編碼器負責產生含浮水印潛在表示；RGB 影像修復模組負責改善 VAE 解碼後 RGB 輸出影像與原始影像之間的品質差異；訊息解碼器則負責從重新編碼後的潛在表示中恢復 32 位元訊息。

整體架構如圖 6 所示，本文方法的資料流可概括為三個階段。第一階段將輸入影像編碼至潛在空間，並結合 32 位元訊息產生含

浮水印潛在表示與含浮水印 RGB 影像；第二階段將含浮水印 RGB 影像與原始影像輸入 RGB 影像修復模組，以產生修復後含浮水印影像；第三階段則將修復後影像分別經由未受攻擊與非幾何攻擊路徑重新編碼至潛在空間，並使用共享權重之訊息解碼器恢復嵌入訊息。

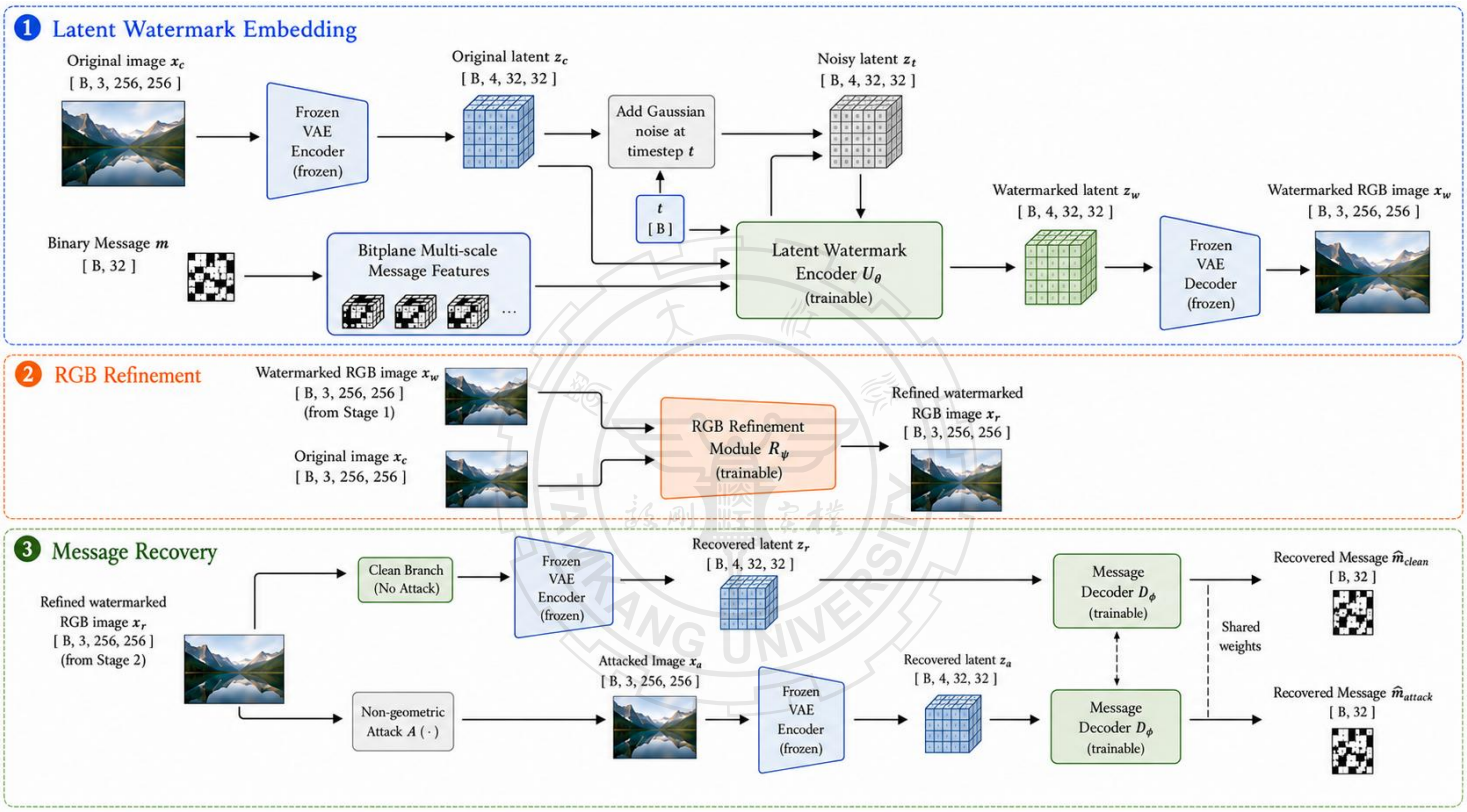


圖 6、本文方法之整體架構

令x_c表示輸入之原始影像，解析度為 256×256，其張量形式可表示為：

$$x_c \in [0,1]^{B\times 3\times 256\times 256} \tag{4}$$

其中，B 為批次大小。在本文正式同影像設定中，條件輸入與品質對齊目標皆為同一張原始影像，因此後續統一以x_c表示原始影像。輸入影像會先由[0,1]正規化至[-1,1]，再透過固定參數 Stable Diffusion 2.1 VAE 編碼器映射至潛在空間：

$$z_c = E_{VAE}(x_c) \tag{5}$$

為簡化符號，公式(5)中的$E_{\mathrm{VAE}}(x_c)$表示包含前述影像範圍轉換後之 VAE 編碼流程；第 3.2.3 節則將此正規化操作明確寫為$\mathcal{N}(\cdot)$，以說明修復後影像與攻擊後影像重新輸入 VAE 編碼器前的範圍轉換。其中E_{VAE}表示固定參數 VAE 編碼器。對於256×256 RGB 影像，本文使用之 VAE 編碼器會產生$4 \times 32 \times 32$的潛在表示，因此：

$$z_c \in \mathbb{R}^{B\times 4\times 32\times 32} \tag{6}$$

欲嵌入之浮水印訊息記為 m，其為長度 32 位元的二進位訊息：

$$m \in \{0,1\}^{B\times 32} \tag{7}$$

上述符號作為後續三階段流程的共同輸入定義。第一階段使用x_c、z_c與 m 產生含浮水印潛在表示；第二階段使用含浮水印 RGB 影像與x_c進行 RGB 影像修復；第三階段則透過固定參數 VAE 編碼

器與共享權重訊息解碼器，分別對未受攻擊影像與攻擊後影像進行訊息恢復。

3.2 三階段浮水印嵌入、修復與恢復流程

本節依據圖 6 所示之整體架構，將本文方法拆分為三個主要階段進行說明。第 3.2.1 節說明階段一之潛在空間浮水印嵌入流程，包含訊息條件建構、位元平面多尺度訊息注入、含浮水印潛在表示生成，以及 VAE 解碼後之 RGB 影像輸出。第 3.2.2 節說明階段二之 RGB 影像修復流程，著重於殘差式修復模組如何改善 VAE 解碼後 RGB 影像品質。第 3.2.3 節則說明階段三之訊息恢復與攻擊分支，包含未受攻擊分支與非幾何攻擊分支如何共用同一訊息解碼器恢復嵌入訊息。

3.2.1 潛在空間浮水印嵌入

階段一的目的在於將原始影像與 32 位元二進位訊息共同轉換為含浮水印潛在表示，並進一步透過固定參數 VAE 解碼器得到含浮水印 RGB 影像。承接第 3.1 節之符號定義，輸入影像已由固定參數 Stable Diffusion 2.1 VAE 編碼器轉換為原始潛在表示z_c，欲嵌入之訊息則記為 m。訓練階段中，模型會依擴散時間步 t 取得加噪

潛在表示z_t，並將z_c、z_t、t與訊息條件共同輸入潛在空間 U-Net 浮水印編碼器，以產生含浮水印潛在表示z_w。

$$z_w = z_c + s(U_\theta([z_c, z_t], t, m) - z_c) \tag{8}$$

其中，U_θ表示潛在空間 U-Net 浮水印編碼器，$[z_c, z_t]$表示沿通道維度串接後的潛在輸入，s 為強度係數。本文正式設定中$s = 1$。需要注意的是，公式(8)中的 m 可視為輸入至浮水印編碼器之訊息條件的簡寫；其具體訊息表示與多尺度注入方式將於後續公式(11)至公式(17)說明。

取得含浮水印潛在表示z_w後，本文使用固定參數 VAE 解碼器將其還原為 RGB 張量。由於 VAE 解碼器直接輸出的張量範圍為[-1,1]，本文先將其記為$\bar{x}_w$：

$$\bar{x}_w = D_{VAE}(z_w) \tag{9}$$

其中，$\bar{x}_w \in [-1,1]^{B\times 3\times 256\times 256}$表示 VAE 解碼器直接輸出的含浮水印 RGB 張量。D_{VAE}表示固定參數 VAE 解碼器。當影像進入後續 RGB 影像修復模組或像素空間攻擊流程時，本文將其轉換至[0,1]範圍：

$$x_w = \frac{\bar{x}_w + 1}{2} \tag{10}$$

因此，後續以$x_w \in [0,1]^{B\times 3\times 256\times 256}$表示供 RGB 影像修復模組使用的含浮水印 RGB 影像。

在訊息條件建構方面，早期對照版本曾採用線性訊息映射，將 32 位元訊息壓縮為低解析度單通道空間特徵，再透過卷積層轉換為 64 通道訊息特徵。此流程可表示為：

$$m \in \{0,1\}^{B\times 32} \rightarrow \text{Linear}(32 \rightarrow 16) \rightarrow \mathbb{R}^{B\times 1\times 4\times 4} \rightarrow \mathbb{R}^{B\times 64\times 4\times 4} \tag{11}$$

此類線性訊息映射雖可將二進位訊息轉換為可與 U-Net 特徵圖結合的形式，但 32 個訊息位元會在進入卷積層之前即被壓縮並混合為單通道空間特徵圖，導致各位元的識別性在早期表示階段便已被合併。為改善此限制，本文正式設定採用位元平面訊息表示，使每個位元在初始階段保有通道層級的識別性，再透過可學習卷積進行後續特徵融合。

具體而言，給定二進位訊息 m，本文先將其重新塑形為具有 32 個通道的位元平面張量：

$$\tilde{m} = Reshape(m), \quad \tilde{m} \in \{0,1\}^{B\times 32\times 1\times 1} \tag{12}$$

接著，位元平面張量會被空間展開至潛在空間 U-Net 訊息分支的起始解析度4×4：

$$\widetilde{m}_4 = \text{Expand}(\widetilde{m}), \quad \widetilde{m}_4 \in \{0,1\}^{B\times 32\times 4\times 4} \tag{13}$$

此處的4×4指的是潛在空間 U-Net 瓶頸層與訊息分支起始位置的最低解析度，而非整個 Stable Diffusion 2.1 VAE 潛在表示的解析度。對於本文使用的256×256 RGB 影像，VAE 潛在表示解析度為32×32，而 U-Net 內部經多層下採樣後的最低特徵解析度為4×4。因此，本文將訊息位元平面先展開至4×4，再由此產生對應 U-Net 不同階段的多尺度訊息特徵。

展開後的位元平面張量會經由訊息特徵擷取層轉換為 64 通道的基礎訊息特徵：

$$M_4^{base} = C_{msg}(\widetilde{m}_4), \quad M_4^{base} \in \mathbb{R}^{B\times 64\times 4\times 4} \tag{14}$$

其中，C_{msg}表示訊息特徵擷取層。位元平面表示的重點並非使每個位元在整個網路中永久保持完全獨立，而是在進入第一層卷積之前先保留各位元的通道識別性。經過C_{msg}後，不同位元通道會透過可學習的卷積融合形成較高維度的訊息特徵。

為了讓訊息條件能夠參與潛在空間 U-Net 中不同解析度的特徵建構，本文進一步由M_4^{base}產生多尺度訊息特徵。對於4×4解析度，M_4^{base}會經由不改變空間解析度的特徵修復分支產生M_4；對於8×8、16×16與32×32解析度，則分別透過包含 1、2 與 3 個上採樣區塊的上採樣分支，將共同的4×4基礎訊息特徵放大至對應解析度，再經由特徵修復分支產生最終訊息特徵。此流程可概括表示為：

$$M_4 = S_4\left(M_4^{base}\right), M_8 = S_8\left(E_1\left(M_4^{base}\right)\right)$$
$$M_{16} = S_{16}\left(E_2\left(M_4^{base}\right)\right), M_{32} = S_{32}\left(E_3\left(M_4^{base}\right)\right) \quad (15)$$

其中，E_1、E_2與E_3分別表示包含 1、2 與 3 個上採樣區塊的上採樣分支，用於將4×4特徵放大至8×8、16×16 與 32×32；S_4、S_8、S_{16}與S_{32}則表示各解析度分支中的 SENet-based 特徵修復。換言之，本文的多尺度訊息特徵並非由單一路徑逐層串接產生，而是由共同的M_4^{base}分別經由不同分支產生，以對應潛在空間 U-Net 解碼路徑中不同解析度的特徵圖。

因此，訊息分支會產生4×4、8×8、16×16 與 32×32四種解析度的 64 通道訊息特徵，分別記為M_4、M_8、M_{16}與M_{32}：

$$M_4 \in \mathbb{R}^{B\times 64\times 4\times 4},\quad M_8 \in \mathbb{R}^{B\times 64\times 8\times 8}$$

$$M_{16} \in \mathbb{R}^{B\times 64\times 16\times 16},\quad M_{32} \in \mathbb{R}^{B\times 64\times 32\times 32} \tag{16}$$

其中，M_4對應潛在空間 U-Net 的瓶頸層與最低解析度上採樣區塊，M_8、M_{16}與M_{32}則分別對應後續8×8、16×16 與 32×32的上採樣階段。由於含浮水印潛在表示的最終解析度為32×32，多尺度訊息特徵能使 32 位元訊息不只在單一瓶頸位置提供條件資訊，而是能沿著解碼路徑逐步參與不同空間尺度的特徵重建。

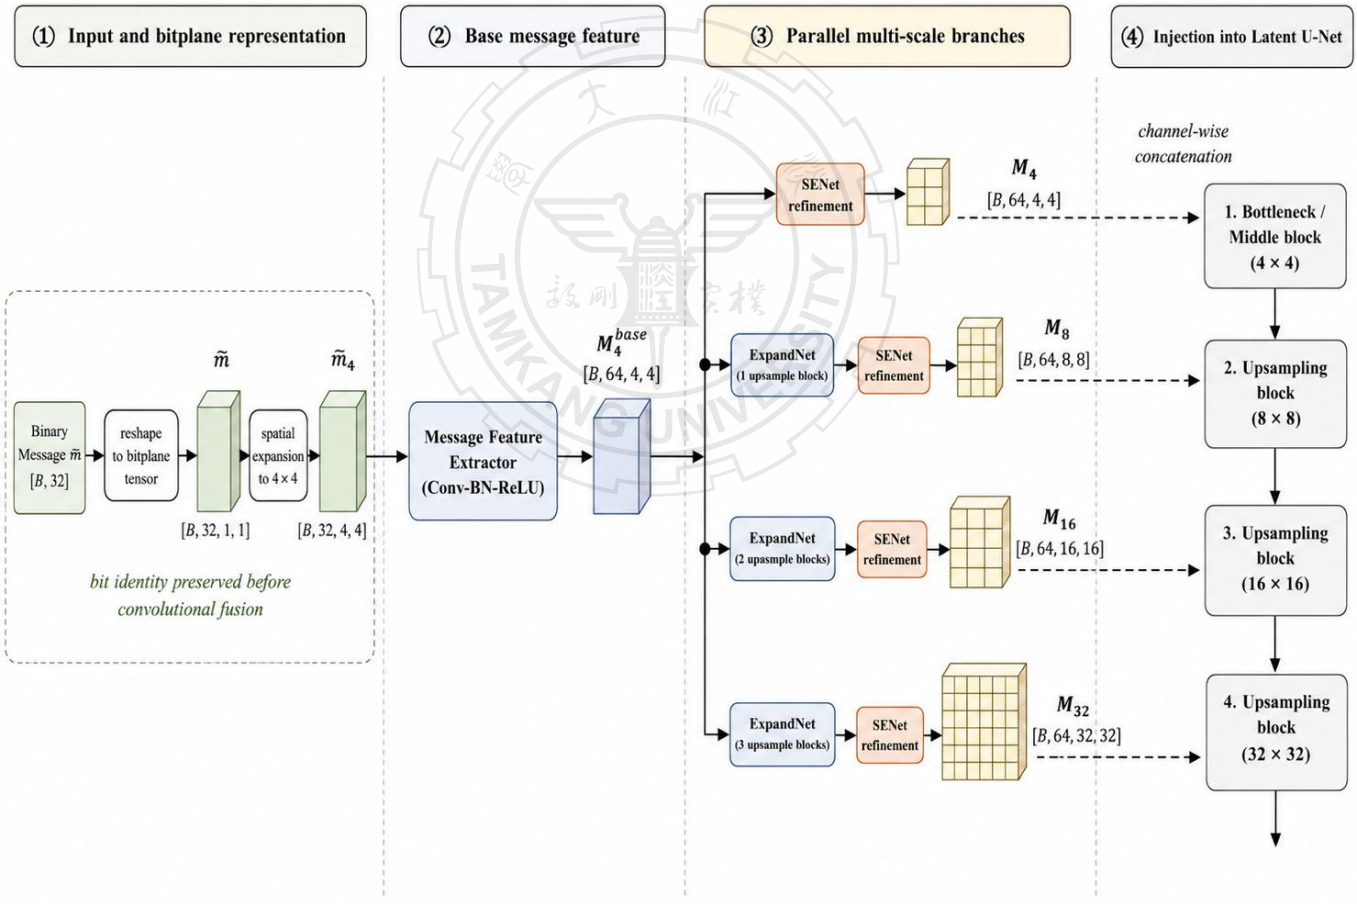


圖 7、位元平面訊息表示與多尺度訊息注入流程

在訊息特徵注入方式上，本文採用通道維度串接。於潛在空間 U-Net 的上採樣路徑中，對於第 l 個解析度階段，令h_l表示目前的解碼端特徵，s_l表示來自編碼端路徑的跳接特徵，M_l表示對應解析度的訊息特徵，則注入後的特徵可表示為：

$$h_l' = \text{Concat}(h_l, s_l, M_l) \tag{17}$$

透過此方式，訊息特徵會與 U-Net 原本的影像特徵及跳接連線特徵共同作為後續卷積區塊的輸入，使模型能根據原始潛在表示、擴散狀態與二進位訊息共同產生含浮水印潛在表示。本文的訊息特徵主要注入 U-Net 中間層、瓶頸層與上採樣路徑，而不直接注入下採樣路徑。這樣的設計使訊息條件更集中地作用於潛在表示重建與含浮水印潛在表示生成階段，避免在早期特徵擷取階段過度干擾原始潛在表示的內容表徵。圖 8 彙整階段一由原始影像與二進位訊息輸入，至產生含浮水印潛在表示與含浮水印 RGB 影像之資料流，後續演算法 1 進一步整理其主要運算步驟。

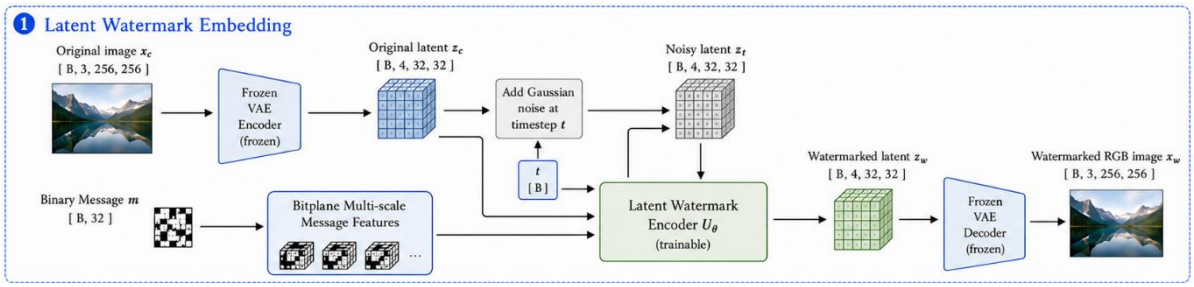


圖 8、階段一之潛在空間浮水印嵌入流程

演算法 1：階段一之潛在空間浮水印嵌入流程

輸入：原始影像x_c、二進位訊息m、擴散時間步t、高斯雜訊ϵ、固定參數 VAE 編碼器E_{VAE}、固定參數 VAE 解碼器D_{VAE}、潛在空間 U-Net 浮水印編碼器U_θ

輸出：含浮水印潛在表示z_w、含浮水印 RGB 影像x_w

1 $z_c \leftarrow E_{\mathrm{VAE}}(x_c)$

2 $z_t \leftarrow AddNoise(z_c, t, \epsilon)$

3 $\tilde{m} \leftarrow Reshape(m)$

4 $\tilde{m}_4 \leftarrow Expand(\tilde{m})$

5 $M_4^{base} \leftarrow C_{msg}(\tilde{m}4)$

6 $M_4, M_8, M_{16}, M_{32} \leftarrow \mathcal{M}_{ms}(M_4^{base})$

7 於 U-Net 中間層、瓶頸層與上採樣路徑中，依對應解析度串接訊息特徵M_l

8 $z_w \leftarrow z_c + s(U_\theta([z_c, z_t], t, m) - z_c)$

9 $\bar{x}_w \leftarrow D_{VAE}(z_w)$

10 $x_w \leftarrow (\bar{x}_w + 1)/2$

11 return (z_w, x_w)

演算法 1 整理階段一的潛在空間浮水印嵌入流程。第 1 行將原始影像編碼為潛在表示z_c，第 2 行依擴散時間步t產生加噪潛在表

示z_t。第 3 行至第 6 行對應 bitplane 訊息表示與多尺度訊息特徵產生流程，將 32 位元訊息轉換為可注入 U-Net 不同解析度層級的訊息特徵。第 7 行說明訊息特徵注入至 U-Net 中間層、瓶頸層與上採樣路徑；第 8 行則由潛在空間 U-Net 浮水印編碼器產生含浮水印潛在表示z_w。最後，第 9 行至第 10 行透過固定參數 VAE 解碼器將z_w轉換為含浮水印 RGB 影像x_w，並將影像範圍轉換至[0,1]以作為後續 RGB 影像修復階段的輸入。

3.2.2 RGB 影像修復

階段二的目的在於改善階段一輸出之含浮水印 RGB 影像品質。由於階段一先在潛在空間中產生含浮水印潛在表示z_w，再透過固定參數 Stable Diffusion 2.1 VAE 解碼器還原至 RGB 空間，因此輸出影像x_w可能受到 VAE 重建誤差與潛在表示修改的影響。為降低含浮水印 RGB 影像與原始影像之間的品質差異，本文在 VAE 解碼器之後加入 RGB 影像修復模組R_ψ，以殘差方式對x_w進行像素空間修正。此種以殘差形式預測影像修正量的設計，與影像復原任務中常見的殘差學習觀點相近[23, 24]。

具體而言，RGB 影像修復模組同時接收含浮水印 RGB 影像x_w與原始影像x_c作為輸入，並沿通道維度進行串接。修復模組不直接

輸出完整影像，而是預測三通道殘差修正量Δx。為避免修復幅度過大而破壞已嵌入之浮水印訊號，本文透過tanh(·)與殘差幅度限制δ_{max}約束修正量範圍：

$$\Delta x = \delta_{\max} \tanh\left(R_{\psi}([x_w, x_c])\right) \tag{18}$$

其中，R_{ψ}表示 RGB 影像修復模組，ψ為其可訓練參數，$[x_w, x_c]$表示沿通道維度串接後的 RGB 輸入，Δx為三通道殘差修正量，δ_{max}則為殘差修正量的最大幅度限制。

取得殘差修正量後，本文將Δx加回階段一輸出的含浮水印 RGB 影像x_w，並透過 clip 函數將影像限制於有效像素範圍，得到修復後含浮水印 RGB 影像x_r：

$$x_r = \text{clip}(x_w + \Delta x, 0, 1) \tag{19}$$

其中，$x_r \in [0,1]^{B\times 3\times 256\times 256}$表示修復後含浮水印 RGB 影像。此設計使 RGB 影像修復模組僅負責學習局部殘差修正，而不取代原有的 VAE 解碼器，也不改變階段一所產生的含浮水印潛在表示。換言之，RGB 影像修復模組位於 VAE 解碼器之後、像素空間攻擊之前，其主要功能是改善輸出影像品質，同時盡量保留後續訊息恢復所需之浮水印訊號。圖 9 彙整階段二中 RGB 影像修復模組之輸

入、殘差修正與輸出流程，後續演算法 2 進一步整理其主要運算步驟。

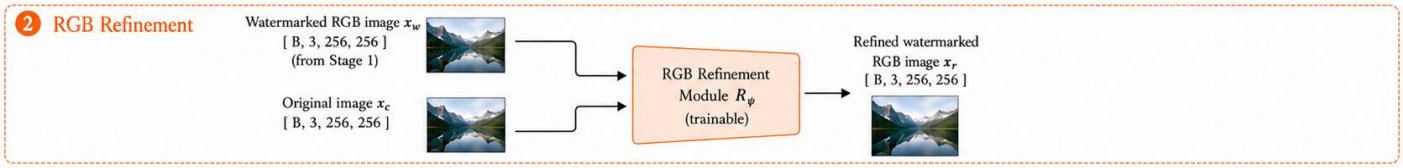


圖 9、階段二之 RGB 影像修復流程

演算法 2：階段二之 RGB 影像修復流程

輸入：含浮水印 RGB 影像x_w、原始影像x_c、RGB 影像修復模組R_ψ、殘差幅度限制δ_{max}

輸出：修復後含浮水印 RGB 影像x_r

1 $x_{cat} \leftarrow Concat(x_w, x_c)$ // 將含浮水印影像與原始影像沿通道維度串接

2 $\Delta x \leftarrow \delta_{max} \tanh\left(R_\psi(x_{cat})\right)$ // 預測受限制範圍內的 RGB 殘差修正量

3 $x_r \leftarrow clip(x_w + \Delta x, 0,1)$ // 將殘差修正量加回含浮水印影像並限制於有效像素範圍

4 return x_r // 輸出修復後含浮水印 RGB 影像

演算法 2 整理階段二的 RGB 影像修復流程。第 1 行對應公式(18)中 RGB 影像修復模組的輸入建構，第 2 行對應殘差修正量Δx的產生，第 3 行則對應公式(19)，將殘差修正量加回含浮水印 RGB 影像並限制於[0,1]範圍。後續階段三將以x_r作為輸入，分別建立未

受攻擊分支與攻擊後分支進行訊息恢復。

3.2.3 訊息恢復與攻擊分支

階段三的目的在於從修復後含浮水印 RGB 影像x_r中恢復嵌入訊息，並同時建立未受攻擊分支與攻擊後分支，以評估浮水印訊號在不同影像擾動下的可恢復性。由於本文的訊息解碼器操作於 Stable Diffusion 2.1 VAE 潛在空間，因此無論是未受攻擊影像或攻擊後影像，皆需先經由固定參數 VAE 編碼器重新轉換為潛在表示，再交由共享訊息解碼器D_ϕ進行訊息預測。

首先，對於未受攻擊分支，修復後含浮水印 RGB 影像x_r位於[0,1]像素範圍。為符合 VAE 編碼器之輸入範圍，本文先定義正規化函數$\mathcal{N}(\cdot)$，將 RGB 影像由[0,1]轉換至[-1,1]：

$$\mathcal{N}(x) = 2x - 1 \tag{20}$$

接著，將正規化後的修復影像輸入固定參數 VAE 編碼器，得到未受攻擊條件下的潛在表示z_r：

$$\mathrm{z_r} = \mathrm{E_{VAE}}\big(\mathcal{N}(\mathrm{x_r})\big) \tag{21}$$

其中，$z_r \in \mathbb{R}^{B\times 4\times 32\times 32}$表示修復後影像重新編碼所得之潛在表

示。訊息解碼器D_ϕ接收z_r後，輸出未受攻擊條件下的訊息預測結果：

$$\hat{m}_{clean} = D_\phi(z_r) \tag{22}$$

其中，$\hat{m}_{clean} \in \mathbb{R}^{B\times 32}$表示未受攻擊條件下預測出的 32 位元訊息連續解碼分數。

另一方面，為模擬影像在傳輸、儲存或後處理過程中可能遭遇之擾動，本文於攻擊後分支中對修復後含浮水印 RGB 影像x_r施加像素空間攻擊函數$A(\cdot)$，得到攻擊後影像x_a：

$$x_a = A(x_r) \tag{23}$$

接著，攻擊後影像同樣先經由正規化函數$\mathcal{N}(\cdot)$轉換至 VAE 編碼器輸入範圍，再透過固定參數 VAE 編碼器取得攻擊後潛在表示z_a：

$$z_a = E_{\mathrm{VAE}}\big(\mathcal{N}(x_a)\big) \tag{24}$$

最後，本文使用與未受攻擊分支相同的訊息解碼器D_ϕ對z_a進行訊息恢復，得到攻擊後訊息預測結果：

$$\hat{m}_{attack} = D_\phi(z_a) \tag{25}$$

其中，$\hat{m}_{attack} \in \mathbb{R}^{B\times 32}$表示攻擊後條件下預測出的 32 位元訊息連續解碼分數。

需要注意的是，未受攻擊分支與攻擊後分支並非使用兩個不同的訊息解碼器，而是共用同一個D_ϕ。此設計使模型在未受攻擊影像與攻擊後影像上皆依據相同的訊息判別規則進行恢復，並避免因分支差異造成評估標準不一致。圖 10 彙整階段三中未受攻擊分支與攻擊分支之訊息恢復流程，後續演算法 3 進一步整理其主要運算步驟。

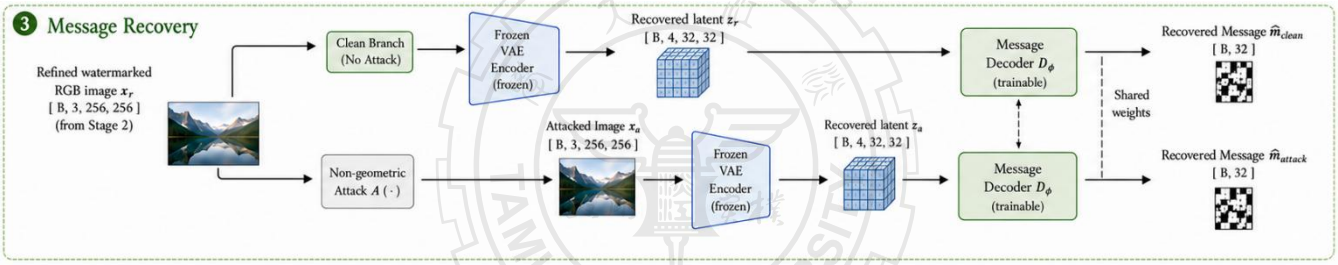


圖 10、階段三之訊息恢復與攻擊分支流程

演算法 3：階段三之訊息恢復與攻擊分支流程

輸入：修復後含浮水印 RGB 影像x_r、像素空間攻擊函數$A(\cdot)$、固定參數 VAE 編碼器E_{VAE}、共享訊息解碼器D_ϕ

輸出：未受攻擊訊息預測$\hat{m}_{clean}$、攻擊後訊息預測$\hat{m}_{attack}$

1 $z_r \leftarrow E_{\mathrm{VAE}}\big(\mathcal{N}(x_r)\big)$ // 將未受攻擊影像正規化後重新編碼至潛在空間

2 $\hat{m}_{clean} \leftarrow D_{\phi}(z_r)$ // 由共享訊息解碼器恢復未受攻擊條件下的訊息

3 $x_a \leftarrow A(x_r)$ // 對修復後含浮水印影像施加像素空間攻擊

4 $z_a \leftarrow E_{\mathrm{VAE}}\big(\mathcal{N}(x_a)\big)$ // 將攻擊後影像正規化後重新編碼至潛在空間

5 $\hat{m}_{attack} \leftarrow D_{\phi}(z_a)$ // 使用相同訊息解碼器恢復攻擊後訊息

6 return $\hat{m}_{clean}, \hat{m}_{attack}$ // 輸出兩條分支的訊息預測結果

演算法 3 整理階段三的訊息恢復與攻擊分支流程。第 1 行至第 2 行對應未受攻擊分支，將修復後影像重新編碼至潛在空間並恢復訊息；第 3 行至第 5 行對應攻擊後分支，先對修復後影像施加像素空間攻擊，再經由相同的 VAE 編碼器與共享訊息解碼器恢復訊息。兩條分支共用同一個訊息解碼器D_{ϕ}，用以確保未受攻擊影像與攻擊後影像皆依據相同的訊息判別規則進行恢復。

3.3 訓練目標與版本設定

前一節已依據圖 6 將本文方法拆分為潛在空間浮水印嵌入、RGB 影像修復，以及訊息恢復與攻擊分支三個階段。本節進一步說明各階段對應之訓練目標與版本設定。本文訓練流程可分為兩個主要部分：第一部分為潛在浮水印基礎模型訓練，用於學習在 Stable Diffusion 2.1 VAE 潛在空間中嵌入與恢復 32 位元二進位訊息；第

二部分為 RGB 影像修復模組訓練，用於改善 VAE 解碼後 RGB 影像品質，並在未受攻擊與非幾何攻擊條件下保留訊息可恢復性。圖 11 整理基礎模型與 RGB 影像修復模組之主要訓練目標流程。

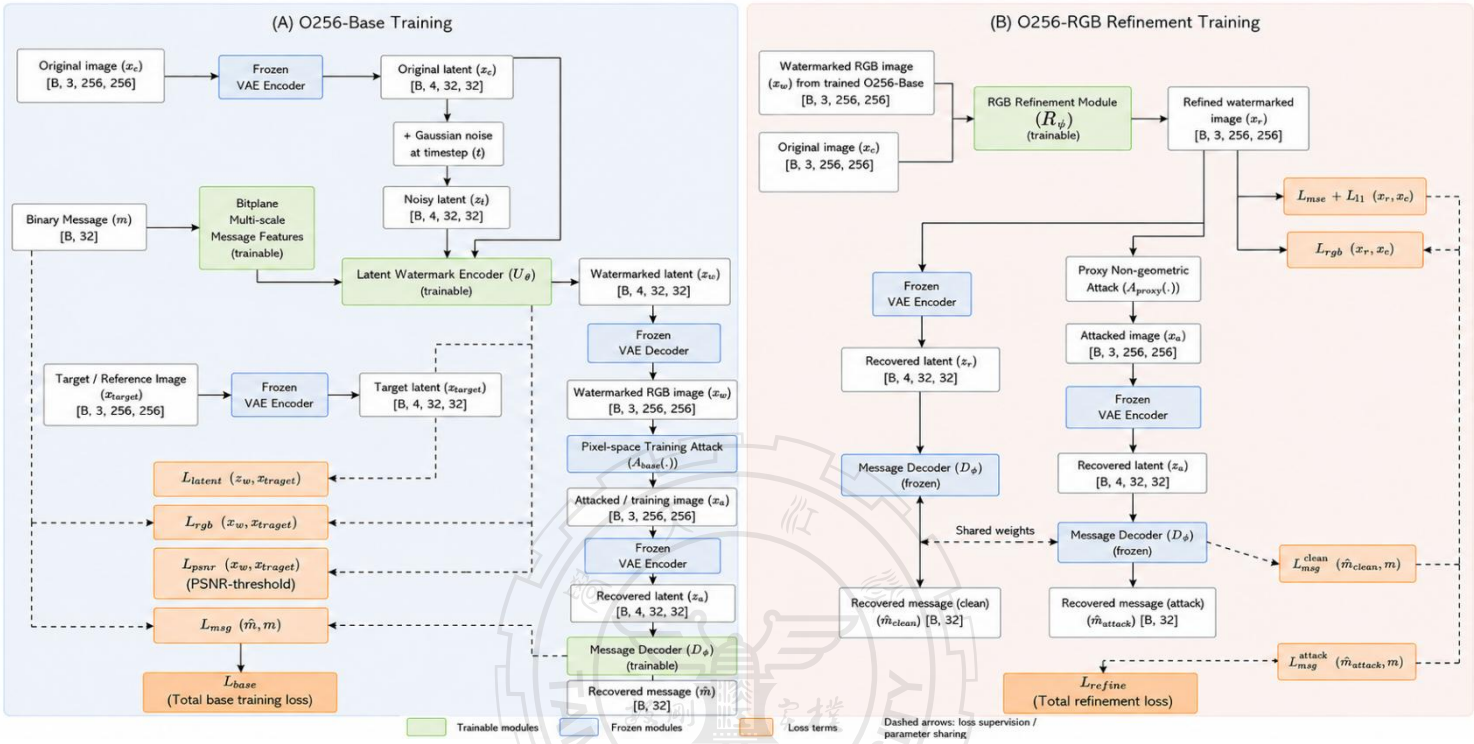


圖 11、基礎模型與 RGB 影像修復模組之訓練目標流程

3.3.1 潛在浮水印基礎模型之訓練目標

在定義潛在浮水印基礎模型的訓練目標之前，需先說明目標潛在表示的來源。本文資料流程中保留原始影像與重建目標影像配對的形式，令x_{target}表示作為重建目標的影像，則其對應潛在表示可定義為：

$$z_{\text{target}} = E_{\text{VAE}}\left(\mathcal{N}\left(x_{\text{target}}\right)\right) \tag{26}$$

正式同影像設定中，x_{target}與x_c來自同一張來源影像，因此：

$$x_{target} = x_c, z_{target} = z_c \tag{27}$$

本文在損失函數中保留z_{target}的符號，是為了區分「作為 U-Net 條件輸入的原始潛在表示」與「作為重建約束目標的目標潛在表示」。需要注意的是，z_{target}並非擴散模型時間步 t 加噪後的加噪潛在表示z_t，而是未加噪的目標潛在表示。

潛在浮水印基礎模型的訓練目標包含潛在層級重建、訊息恢復、VAE 解碼後 RGB 一致性，以及 RGB MSE 門檻約束。其總損失可表示為：

$$\mathcal{L}_{\text{base}} = \lambda_{\text{latent}}\mathcal{L}_{\text{latent}} + \lambda_{\text{msg}}\mathcal{L}_{\text{msg}} + \lambda_{\text{rgb}}\mathcal{L}_{\text{rgb}} + \lambda_{\text{hinge}}\mathcal{L}_{\text{hinge}} \tag{28}$$

其中，各項λ為控制不同訓練目標權重之超參數，用於平衡潛在表示重建、訊息恢復與 RGB 空間一致性之間的影響。除分階段訓練中依階段調整的權重外，其餘具體設定將於第四章實驗設定中說明。

其中，$\mathcal{L}_{latent}$用於約束含浮水印潛在表示與目標潛在表示之間的距離，可定義為：

$$\mathcal{L}_{\text{latent}} = \text{MSE}\left(z_w, z_{\text{target}}\right) \tag{29}$$

在目前同影像設定下，由於$z_{target} = z_c$，因此此項亦可視為約束z_w與原始潛在表示z_c之間的距離。此項損失使z_w在嵌入浮水印訊息後，仍維持與目標潛在表示相近，避免潛在輸出因訊息嵌入而產生過大偏移。

訊息恢復損失$\mathcal{L}_{msg}$用於訓練訊息解碼器，使其能從重新編碼後的潛在表示中恢復原始二進位訊息。令$\mathcal{A}_{base}(\cdot)$表示潛在浮水印基礎模型訓練中使用的像素空間失真算子。含浮水印影像x_w經由$\mathcal{A}_{base}(\cdot)$模擬像素空間失真後，再透過固定參數 VAE 編碼器重新映射至潛在空間，形成重新編碼後的潛在表示：

$$\begin{aligned} \tilde{x}_w &= \mathcal{A}_{base}(x_w), \\ z_a &= E_{\text{VAE}}\left(\mathcal{N}(\tilde{x}_w)\right). \end{aligned} \tag{30}$$

其中，z_a表示經像素空間橋接流程後重新編碼得到的潛在表示，並作為訊息解碼器的輸入。令D_ϕ表示訊息解碼器，則：

$$\hat{m} = D_\phi(z_a) \tag{31}$$

其中，$\hat{m} \in \mathbb{R}^{B\times 32}$表示訊息解碼器對 32 位元二進位訊息的連續解碼分數。此輸出未經 Sigmoid 函數轉換，亦非機率值；計算位元

準確率時，才進一步進行四捨五入與範圍裁切。基礎模型訓練中的訊息恢復損失可寫為：

$$\mathcal{L}_{\text{msg}} = \text{MSE}(\hat{m}, m) = \text{MSE}\big(D_{\phi}(z_a), m\big) \tag{32}$$

本文採用 MSE 作為訊息恢復損失，而非 BCE。此設定與本文實作中的訊息解碼器輸出形式一致，使解碼器學習將重新編碼後潛在表示中的浮水印訊號回歸至原始 32 位元二進位訊息。

RGB 一致性損失則用於約束 VAE 解碼後的 RGB 輸出，使含浮水印潛在表示經解碼器還原後不致產生過大的 RGB 空間偏移。由於此項損失在 VAE 解碼器輸出張量上計算，而該張量範圍為[-1,1]，因此令：

$$\bar{x}_{\text{target}} = D_{\text{VAE}}\big(z_{\text{target}}\big) \tag{33}$$

則 RGB 一致性損失可表示為：

$$\mathcal{L}_{\text{rgb}} = \text{MSE}\big(\bar{x}_w, \bar{x}_{\text{target}}\big) = \text{MSE}\left(D_{\text{VAE}}(z_w), D_{\text{VAE}}\big(z_{\text{target}}\big)\right) \tag{34}$$

需要特別說明的是，基礎模型中的 RGB 目標並非原始[0,1]RGB 真值影像，而是目標潛在表示經固定參數 VAE 解碼器還原後的 RGB 張量。換言之，基礎模型的 RGB 一致性主要約束 VAE

解碼後潛在輸出之間的一致性，而不是直接對原始影像做像素層級重建。原始 RGB 輸出與原始影像之間的品質修復，則主要由後續 RGB 影像修復模組處理。

為避免 VAE 解碼後 RGB 輸出與目標解碼影像之間的 MSE 過大，本文另加入由 PSNR 目標轉換而來的門檻損失。令P_{target}表示目標 PSNR，且由於此處 RGB 張量範圍為[-1,1]，其動態範圍為$L = 2$，因此其對應之 MSE 門檻值可表示為：

$$\tau_{MSE} = \frac{L^2}{10^{\frac{P_{target}}{10}}} \tag{35}$$

正式設定中$P_{target} = 36$且$L = 2$，因此：

$$\tau_{MSE} = \frac{2^2}{10^{\frac{36}{10}}} \tag{36}$$

基於此，PSNR 門檻損失可定義為：

$$\mathcal{L}_{\text{hinge}} = \max\left(0, \mathcal{L}_{\text{rgb}} - \tau_{\text{MSE}}\right) \tag{37}$$

此設計使潛在浮水印基礎模型在學習訊息嵌入與恢復的同時，也維持解碼後 RGB 影像的基本品質約束。當$\mathcal{L}_{\text{rgb}}$已低於目標 PSNR 對應之 MSE 門檻時，此項損失不再額外懲罰；反之，當解碼後 RGB

輸出與目標解碼影像之間的誤差過大時，門檻損失會對其施加額外約束。整體而言，基礎模型訓練的目的並非直接產生最終 RGB 輸出，而是先建立可在潛在空間中嵌入、傳遞與恢復 32 位元訊息的基礎模型。

3.3.2 RGB 影像修復模組之訓練目標

在潛在浮水印基礎模型訓練完成後，本文進一步訓練 RGB 影像修復模組R_ψ，用以改善 VAE 解碼後含浮水印 RGB 影像的視覺品質。此階段以前一階段輸出的含浮水印 RGB 影像x_w與原始影像x_c作為輸入，並依第 3.2.2 節所述之殘差式修復流程產生修復後含浮水印 RGB 影像x_r。在 RGB 影像修復模組訓練過程中，已訓練完成之潛在浮水印基礎模型、固定參數 VAE 編碼器與解碼器，以及訊息解碼器D_ϕ皆不更新，僅更新 RGB 影像修復模組R_ψ之參數。

RGB 影像修復模組的訓練目標同時包含影像品質約束、訊息恢復約束與殘差修正約束。其總損失可表示為：

$$\mathcal{L}_{\text{refine}} = \lambda_{\text{mse}}\mathcal{L}_{\text{mse}} + \lambda_{\ell_1}\mathcal{L}_{\ell_1} + \lambda_{\text{msg}}\mathcal{L}_{\text{msg}}^{\text{clean}} + \lambda_{\text{atk}}\mathcal{L}_{\text{msg}}^{\text{attack}} + \lambda_{\text{reg}}\mathcal{L}_{\text{reg}} \quad (38)$$

其中，λ_{mse}、λ_{ℓ_1}、λ_{msg}、λ_{atk}與λ_{reg}分別表示各損失項之權重，用於平衡影像品質、未受攻擊訊息恢復、攻擊後訊息恢復，以及修

復幅度控制。

首先，影像品質約束用於使修復後影像x_r接近原始影像x_c。本文使用 MSE 損失與L_1損失共同約束 RGB 空間差異，其定義如下：

$$\mathcal{L}_{\text{mse}} = \text{MSE}(x_r, x_c)$$

$$\mathcal{L}_{\ell 1} = |x_r - x_c|_{1.} \tag{39}$$

其中$\mathcal{L}_{\text{mse}}$用於懲罰整體像素誤差，$\mathcal{L}\ell_1$則用於降低局部像素差異，使修復後影像在整體亮度、顏色與局部細節上更接近原始影像。

然而，若 RGB 影像修復模組僅以影像品質為目標，可能會在修復過程中削弱或抹除階段一已嵌入之浮水印訊號。因此，本文同時加入未受攻擊分支的訊息恢復損失。依第 3.2.3 節所述，修復後影像x_r會先正規化並重新輸入固定參數 VAE 編碼器，再由共享訊息解碼器D_ϕ恢復訊息：

$$\hat{m}_{clean} = D_\phi\left(E_{\text{VAE}}\big(\mathcal{N}(x_r)\big)\right) \tag{40}$$

未受攻擊訊息恢復損失定義為：

$$\mathcal{L}_{msg}^{clean} = MSE(\hat{m}_{clean}, m) \tag{41}$$

其中，$\mathcal{L}_{msg}^{clean}$用於確保修復後影像在未受攻擊條件下仍保留可被訊息解碼器恢復的 32 位元訊息。

為進一步提升修復後影像在非幾何攻擊下的訊息可恢復性，本文於 RGB 影像修復模組訓練中加入攻擊後訊息恢復損失。令$\mathcal{A}_{proxy}(\cdot)$表示 RGB 修復訓練中使用的像素空間代理攻擊函數，則攻擊後訊息預測可表示為：

$$\hat{m}_{attack} = D_{\phi}\left(E_{\text{VAE}}\left(\mathcal{N}\left(\mathcal{A}_{proxy}(x_r)\right)\right)\right) \tag{42}$$

攻擊後訊息恢復損失定義為：

$$\mathcal{L}_{msg}^{attack} = \text{MSE}(\hat{m}_{attack}, m) \tag{43}$$

其中，$\mathcal{L}_{msg}^{attack}$用於約束 RGB 影像修復模組，使其在改善影像品質時，仍保留經像素空間代理攻擊後可被恢復的浮水印訊號。需要注意的是，此處的攻擊分支主要用於訓練時提供強健性約束，具體攻擊類型與評估設定將於第四章實驗設定中說明。

最後，為避免 RGB 影像修復模組對階段一輸出的含浮水印影像x_w產生過大改動，本文加入殘差正則化項：

$$\mathcal{L}_{reg} = |x_r - x_w|_1 \tag{44}$$

此項損失限制修復後影像x_r與修復前含浮水印影像x_w之間的差異，使 RGB 影像修復模組傾向於進行必要的局部修正，而非重新生成整張影像。整體而言，RGB 影像修復模組之訓練目標並非單純追求影像品質提升，而是在影像品質、未受攻擊訊息恢復與攻擊後訊息恢復之間取得平衡。

3.3.3 訓練版本與模型設定

前兩小節已分別定義潛在浮水印基礎模型與 RGB 影像修復模組之訓練目標。本小節進一步整理本文所使用之主要訓練版本與模型設定。整體而言，本文方法可分為兩個主要訓練階段：首先訓練潛在浮水印基礎模型，使模型能於 Stable Diffusion 2.1 VAE 潛在空間中嵌入並恢復 32 位元二進位訊息；接著固定已訓練完成之基礎模型、VAE 編碼器與解碼器，以及訊息解碼器，進一步訓練 RGB 影像修復模組，以改善 RGB 影像品質並保留訊息可恢復性。

本文首先建立 O256-Base 作為潛在浮水印基礎模型。在此版本中，主要可訓練模組為潛在空間 U-Net 浮水印編碼器U_θ與訊息解碼器D_ϕ，固定參數 Stable Diffusion 2.1 VAE 編碼器與解碼器則僅作為

影像與潛在表示之間的轉換模組。O256-Base 的訓練目標為第 3.3.1 節所定義之$\mathcal{L}_{base}$，用以同時約束潛在表示重建、訊息恢復、RGB 一致性與 PSNR 門檻損失。

在 O256-Base 訓練完成後，本文進一步加入 RGB 影像修復模組R_{ψ}，形成 O256-RGB 系列模型。此階段不改變潛在空間浮水印嵌入流程，也不重新訓練基礎模型；RGB 影像修復模組僅接收含浮水印 RGB 影像x_w與原始影像x_c，並依第 3.2.2 節所述之殘差式修復流程產生修復後含浮水印 RGB 影像x_r。其訓練目標為第 3.3.2 節所定義之$\mathcal{L}_{refine}$。

然而，原始 O256-RGB 基準版本雖能明顯改善 RGB 影像品質，但在部分非幾何攻擊條件下，尤其是 Dropout 類型擾動下，訊息恢復能力仍可能下降。基於此，本文在相同 RGB 影像修復器架構與前向流程下，進一步採用 Dropout 感知式 RGB 修復訓練排程。此訓練排程包含兩個主要修訂方向：其一為 Dropout 平衡式穩定化，用於提升修復後影像在 Dropout 類型擾動下的訊息保留能力；其二為解碼器感知式最終校準，用於在固定訊息解碼器條件下進一步平衡影像品質、未受攻擊訊息恢復與攻擊後訊息恢復。

為避免混淆，本文將 O256-Base、原始 O256-RGB 基準版本、

Dropout 平衡式穩定化與解碼器感知式最終校準視為不同訓練版本，而非完全不同的模型架構。各版本的主要差異在於是否加入 RGB 影像修復模組，以及 RGB 影像修復模組所採用的訓練排程與損失權重配置。表 1 整理本文主要模型版本與訓練設定之差異。

表 1、本文主要訓練版本與模型設定

模型版本	可訓練模組	固定模組	主要訓練目標	模型定位
O256-Base	U_θ, D_ϕ	Stable Diffusion 2.1 VAE	$\mathcal{L}_{base}$	潛在空間浮水印嵌入與訊息恢復基礎模型
原始 O256-RGB 基準版本	R_ψ	O256-Base VAE、D_ϕ	$\mathcal{L}_{refine}$	改善 RGB 影像品質之早期修復版本
Dropout 平衡式穩定化	R_ψ	O256-Base VAE、D_ϕ	加強 Dropout 條件下之訊息恢復約束	提升弱攻擊條件下之穩定性
解碼器感知式最終校準	R_ψ	O256-Base VAE、D_ϕ	平衡影像品質、未受攻擊訊息恢復與攻擊後訊息恢復	本文最終 O256-RGB 設定

其中，原始 O256-RGB 基準版本由早期 RGB 影像修復流程形成，該流程包含階段 A、階段 B、階段 B+與階段 C。這些階段並非不同模型架構，而是同一個 RGB 影像修復模組在不同損失權重設定下的連續訓練流程，主要用於由影像品質導向逐步加入未受攻擊與弱非幾何攻擊條件下的訊息保留約束。本文後續以階段 C 所形

成之模型作為原始 O256-RGB 基準版本，綜合上述，表 1 所列版本構成本文第四章實驗比較與消融分析之方法基礎；具體資料集、攻擊設定、評估指標與實驗結果將於第四章進一步說明。

第四章 實驗結果與分析

本章依據前一章所提出之方法，進行實驗結果與分析，以驗證本文方法在影像品質、訊息恢復能力、非幾何攻擊強健性與計算成本上的表現。由於本文方法包含潛在空間浮水印嵌入、RGB 影像修復，以及最終修訂階段所加入之 Dropout 感知式 RGB 修復訓練排程，因此本章實驗不僅比較本文方法與基準方法之整體性能，也進一步分析 RGB 修復流程在影像品質改善、訊息保留能力與最弱攻擊條件下強健性之間所形成的折衷關係。

本章首先會說明資料集、比較方法、評估指標與攻擊設定；接著比較 DiffW-like、O256-Base、原始 O256-RGB 基準版本與最終校準設定於正式測試集上的整體表現；再針對非幾何攻擊強健性、Dropout 攻擊下的最低 BA、RGB 修復設計演進與分階段消融實驗進行分析；最後整理不同方法之訓練成本、完整準備成本與推論效率，並於本章小結歸納實驗結果所支持之主要觀察。

4.1 實驗設定

本節說明本文實驗所使用之資料集、影像解析度、比較方法、評估指標與攻擊設定。首先，在資料集與實驗協定方面，本文使用

Microsoft COCO（Common Objects in Context, COCO）資料集[25]作為主要資料來源，並採用 train10000 作為訓練資料，locked finaltest1000 作為正式測試資料，以確保後續所有方法皆在一致且固定的測試條件下進行比較。此外，本文已確認 train10000 與 finaltest1000 之間不存在檔案層級重疊，重疊數為 0，因此正式測試結果不受訓練與測試影像重複之影響。

本文採用256 × 256作為正式影像解析度，主要是為了配合 Stable Diffusion 2.1 VAE 之潛在空間解析度與本文多尺度訊息注入設計。對於256 × 256 RGB 影像，固定參數 VAE 會產生32 × 32的潛在表示，使本文可在4 × 4、8 × 8、16 × 16 與 32 × 32等多個尺度上建立訊息特徵並注入潛在空間 U-Net。若改用較低解析度，例如128 × 128，則對應之潛在表示解析度與 U-Net 內部特徵尺度皆會改變，需重新調整訊息分支與訓練設定。為避免解析度差異造成不公平比較，本文不直接引用既有方法於其他解析度下的原始結果，而是在統一 256×256 影像解析度、32 位元訊息長度與相同攻擊評估協定下，重新訓練並比較 DiffW-like、O256-Base、原始 O256-RGB 基準版本，以及最終修訂階段形成之 Dropout 感知式 RGB 修復訓練排程。表 2 彙整本文主要實驗設定。

表 2、實驗設定摘要

項目	設定
資料集	COCO（123,287 張影像）
訓練資料	train10000
測試資料	Locked finaltest1000
影像解析度	256×256
訊息長度	32bits
正式主結果 seed	61、62
補充驗證 seed	63
原始影像(x_c)	固定 COCO 測試影像
Stable Diffusion 2.1 VAE	固定參數，不參與訓練
擴散時間步總數(T)	1000
反向取樣步數(S)	3
反向取樣方式	類 DDIM 廣義反向取樣，非等距選取時間步
O256-Base 推論流程	以(S=3)進行反向取樣，產生含浮水印影像(x_w)
RGB 修復推論流程	於 O256-Base 輸出後，額外執行一次 RGB 修復器前向傳遞，產生修復後影像(x_r)
最終修復設定	不改變 RGB 修復器架構，主要差異在最終修復器訓練協定與損失權重配置
RGB 修復配對資料	僅用於 RGB 修復模組訓練，不屬於正式推論流程
影像品質指標	PSNR,SSIM,LPIPS
強健性指標	位元準確率(Bit Accuracy,BA)
強健性評估範圍	11 種非幾何攻擊
推論時間表示方式	平均每張影像耗時，單位為 ms/image

其中，T 表示擴散雜訊排程中的擴散時間步總數，本文設定為 1000；S 則表示推論階段實際執行的反向取樣步數，本文設定為 3。本文延續 DiffW 將不同擴散時間步下之條件式編碼操作視為編碼器操作的觀點，並採用與其一致的 T=1000、S=3 加速取樣設定[6]。訓練階段中，每個最佳化器步驟會從 0 至 T-1 的時間步範圍中隨機

抽取一個時間步 t，並依據該時間步產生加噪潛在表示，使模型學習不同噪聲條件下的浮水印嵌入。也就是說，O256-Base 於推論時並不執行完整 1000 步反向擴散流程，而是從完整時間步序列中選取三個非等距時間步進行加速反向取樣。

RGB 修復相關設定則是在 O256-Base 產生含浮水印影像x_w後，額外執行一次 RGB 修復器前向傳遞，產生修復後之含浮水印影像x_r。需要注意的是，RGB 修復配對資料產生僅屬於 RGB 修復模組的訓練前準備流程，其目的為產生(x_w, x_c)訓練配對資料；在正式推論階段，已訓練完成之 RGB 修復器僅需執行一次前向傳遞，並不需要重新產生配對資料，也不會增加反向取樣步數 S。

本文最終修訂階段之 Dropout 感知式 RGB 修復訓練排程皆沿用相同的 RGB 修復器架構，差異不在於新增模型結構，而在於最終修復器訓練協定與損失權重配置。具體而言，此訓練排程先透過 Dropout 平衡式穩定化避免 RGB 修復器在提升影像品質時削弱 Dropout 攻擊後仍需保留的浮水印訊號，再進一步透過解碼器感知式最終校準，利用固定參數之訊息解碼器D_ϕ約束未受攻擊影像與經 Dropout 攻擊後影像的訊息可恢復性。因此，最終校準設定並非改變 RGB 修復器架構，而是對修復器訓練協定進行針對性校準。

在比較方法方面，本文依據第三章表 1 所定義之主要訓練版本，選取 DiffW-like、O256-Base、原始 O256-RGB 基準版本，以及最終修訂之 Dropout 感知式 RGB 修復訓練排程作為本章主要比較對象。其中，DiffW-like 作為條件式擴散浮水印方法之本地比較基線；O256-Base 用於觀察本文潛在空間浮水印基礎模型在未加入 RGB 影像修復時的表現；原始 O256-RGB 基準版本則用於分析早期 RGB 影像修復對影像品質與訊息保留能力的影響；最終修訂之 Dropout 感知式 RGB 修復訓練排程則用於驗證 Dropout 平衡式穩定化與解碼器感知式最終校準對最弱攻擊條件下訊息恢復能力的改善效果。表 3 彙整本章主要比較方法與其實驗定位。

表 3、本章主要比較方法與實驗定位

方法或設定	與本文方法之關係	本章實驗定位
DiffW-like	本地重訓比較基線	作為條件式擴散浮水印方法之主要比較基準
O256-Base	潛在浮水印基礎模型	評估未加入 RGB 修復時之基本性能
原始 O256-RGB 基準版本	O256-Base 加上早期 RGB 修復模組	觀察 RGB 修復對影像品質與訊息保留能力之初步影響
Dropout 感知式 RGB 修復訓練排程	Dropout 平衡式穩定化與解碼器感知式最終校準	作為本文最終修訂設定，評估最弱攻擊條件下之改善效果

需要說明的是，本文所使用之 DiffW-like 並非直接引用 DiffW 原論文之官方數據，也非使用其官方模型檢查點，而是依據 DiffW

類型方法之條件式擴散浮水印概念，在本文統一實驗協定下重新實作、重新訓練並重新評估之本地比較基線。DiffW-like 與本文方法皆採用相同 COCO 資料來源、256×256 影像解析度、32 位元訊息長度、locked finaltest1000 正式測試集與相同非幾何攻擊評估流程。因此，本文中的 DiffW-like 結果應理解為共同測試協定下之比較基準，而非原始 DiffW 論文之官方結果。

正式強健性評估聚焦於非幾何攻擊，包含隨機像素遮蔽、高斯模糊、高斯雜訊、JPEG 壓縮、中值濾波與椒鹽雜訊等常見影像處理。這些攻擊主要模擬影像在壓縮、濾波、雜訊與局部像素破壞下的失真情境，不包含裁切、旋轉等幾何變換。近年影像浮水印評估逐漸納入更廣泛的攻擊情境，例如幾何變換、影像編輯與生成式模型相關失真[26, 27]。然而，本文主要研究目標為潛在空間浮水印嵌入與 RGB 影像修復對影像品質及非幾何攻擊強健性之影響，因此本章正式強健性評估聚焦於壓縮、濾波、雜訊與遮蔽等非幾何攻擊；幾何攻擊與影像編輯類型攻擊則於後續研究限制與未來展望中討論。

本文實驗結果分為正式實驗、設計演進實驗與補充支持性實驗三類。正式實驗係指使用 locked finaltest1000 與固定正式評估協定

所得之結果，並作為本章主比較表、非幾何攻擊強健性分析、計算成本與推論效率分析之主要依據。其中，exp52 與 exp53 為最終校準設定之從零開始完整訓練正式重跑，分別使用不同 seed 進行完整訓練與評估，因此作為本文最終主結果；exp54 則為 seed63 額外補充驗證，其最低 BA 接近但未達 90%門檻，因此僅用於說明最終設定在不同 seed 下仍存在邊界情況，不列入嚴格通過之最終主結果。

相較之下，階段 A 至階段 C、Dropout 平衡式穩定化與其他中間實驗主要用於說明 RGB 修復設計演進與 Dropout 感知式 RGB 修復訓練排程的形成過程。其中，Dropout 平衡式穩定化用於驗證提高最弱攻擊條件下訊息保留能力的可行性；解碼器感知式最終校準則在此基礎上進一步約束未受攻擊影像與經 Dropout 攻擊後影像的訊息可恢復性，作為本文最終修訂設定。補充支持性實驗則包含 DiffW-like 長訓練對照、成本測時與推論效率分析等，用於輔助說明本文方法在影像品質、強健性與效率之間的相對定位，但不與正式主結果混為同一層級比較。

4.2 整體性能比較

本節比較 DiffW-like、O256-Base、原始 O256-RGB 基準版本，以及 Dropout 感知式 RGB 修復訓練排程中的 Dropout 平衡式穩定化與解碼器感知式最終校準設定於正式測試集上的整體表現。評估指標包含影像品質指標 PSNR、SSIM 與 LPIPS，以及訊息恢復能力指標未受攻擊 BA、非幾何攻擊平均 BA 與最低 BA。其中，非幾何攻擊平均 BA 為 11 種正式非幾何攻擊條件下之平均位元準確率，不包含未受攻擊條件；最低 BA 則表示所有正式非幾何攻擊中表現最弱者。

表 4 彙整 DiffW-like、O256-Base、原始 O256-RGB 基準版本、Dropout 平衡式穩定化與解碼器感知式最終校準於正式測試集上的整體表現。表中 PSNR、SSIM 與 LPIPS 皆以原始影像作為比較基準；未受攻擊 BA 不納入非幾何攻擊平均 BA 的計算。

由表 4 可知，DiffW-like 在正式比較基準中具有最高的非幾何攻擊平均 BA 與最低 BA，顯示其在此正式設定下具有良好的訊息恢復強健性。然而，其 PSNR、SSIM 與 LPIPS 皆明顯低於本文後續修復設定，代表影像品質仍有改善空間。相較之下，O256-Base

雖能維持高未受攻擊 BA，但影像品質與非幾何攻擊下的最低 BA 皆不足，顯示僅依靠潛在空間浮水印嵌入模型尚無法同時兼顧影像品質與攻擊後訊息恢復能力。

表 4、正式測試集上之整體性能比較

方法 / 設定	實驗定位	seeds	PSNR↑	SSIM↑	LPIPS↓	未受攻擊 BA↑	非幾何攻擊平均 BA↑	最低 BA↑
DiffW-like	正式比較基準	61	26.4236	0.8362	0.206004	100.00%	99.35%	95.47%
O256-Base	本文基礎模型	61	24.7037	0.7018	0.093499	99.30%	87.33%	70.38%
原始 O256-RGB 基準版本	早期完整版本	61	32.9034	0.9589	0.046085	95.81%	87.38%	72.93%
Dropout 平衡式穩定化（exp40）	前置穩定化結果	61	33.9372	0.9819	0.040887	99.96%	98.77%	91.01%
Dropout 平衡式穩定化（exp41）	邊界條件觀察	62	34.0293	0.9820	0.044326	99.98%	98.68%	89.94%
解碼器感知式最終校準（exp52）	最終主結果	62	34.0379	0.9825	0.045133	99.99%	98.76%	90.33%
解碼器感知式最終校準（exp53）	最終主結果	61	33.9522	0.9825	0.040024	99.85%	98.58%	91.36%

原始 O256-RGB 基準版本在加入 RGB 影像修復後，PSNR 由 O256-Base 的 24.7037dB 提升至 32.9034dB，SSIM 由 0.7018 提升至 0.9589，LPIPS 也由 0.0934 降低至 0.046085，顯示 RGB 修復模組能有效改善影像品質。然而，原始 O256-RGB 基準版本的未受攻擊 BA 降至 95.81%，非幾何攻擊平均 BA 僅為 87.38%，最低 BA 也僅為 72.93%。此結果表示，早期 RGB 修復雖可改善視覺品質，

但仍可能削弱攻擊後仍需保留的浮水印訊號，特別是在最弱攻擊條件下仍存在明顯不足。

為改善上述問題，本文於最終修訂階段引入 Dropout 感知式 RGB 修復訓練排程。首先，Dropout 平衡式穩定化結果顯示，exp40 可將最低BA提升至91.01%，而exp41則將最低BA提升至89.94%。雖然 exp41 距離 90%門檻仍有 0.06 個百分點差距，但相較於原始 O256-RGB 基準版本的 72.93%，已大幅提高最弱攻擊條件下的訊息保留能力。這表示將 Dropout 攻擊壓力納入修復訓練流程，確實有助於改善原始 RGB 修復造成的強健性不足問題。

在此基礎上，解碼器感知式最終校準進一步利用固定參數之訊息解碼器約束修復後影像與經 Dropout 攻擊後影像的訊息可恢復性。在此基礎上，解碼器感知式最終校準進一步利用固定參數之訊息解碼器，約束修復後影像與經 Dropout 攻擊後影像的訊息可恢復性。exp52 在隨機種子 62 下取得 PSNR 為 34.0379dB、SSIM 為 0.9825、LPIPS 為 0.045133、未受攻擊 BA 為 99.99%、非幾何攻擊平均 BA 為 98.76%，以及最低 BA 為 90.33%；exp53 在隨機種子 61 下取得 PSNR 為 33.9522dB、SSIM 為 0.9825、LPIPS 為 0.040024、未受攻擊 BA 為 99.85%、非幾何攻擊平均 BA 為 98.58%，以及最低 BA 為

91.36%。兩組從零開始完整訓練之正式重跑皆通過最低 BA90%門檻，顯示最終校準設定能在維持高影像品質的同時，提高最弱攻擊條件下的訊息恢復可靠性。

表 5、原始 O256-RGB 基準版本與最終校準設定之整體差異

指標	原始 O256-RGB 基準版本	最終校準設定平均值（exp52/exp53）	變化
PSNR↑	**32.9034**	**33.9951**	**+1.0917dB**
SSIM↑	**0.9589**	**0.9825**	**+0.0236**
LPIPS↓	**0.046085**	**0.042579**	**-0.003506**
未受攻擊 BA↑	**95.81%**	**99.92%**	**+4.11 個百分點**
非幾何攻擊平均 BA↑	**87.38%**	**98.67%**	**+11.29 個百分點**
最低 BA↑	**72.93%**	**90.85%**	**+17.92 個百分點**

由表 5 可進一步觀察到，相較於原始 O256-RGB 基準版本，最終校準設定不僅使 PSNR 與 SSIM 進一步提升，LPIPS 也略為下降，同時大幅改善未受攻擊 BA、非幾何攻擊平均 BA 與最低 BA。其中，最低 BA 由 72.93%提升至平均 90.85%，提升幅度達 17.92 個百分點，顯示最終修訂的主要效果並非單純提升平均表現，而是補強原始 RGB 修復流程在最弱攻擊條件下的訊息恢復缺口。

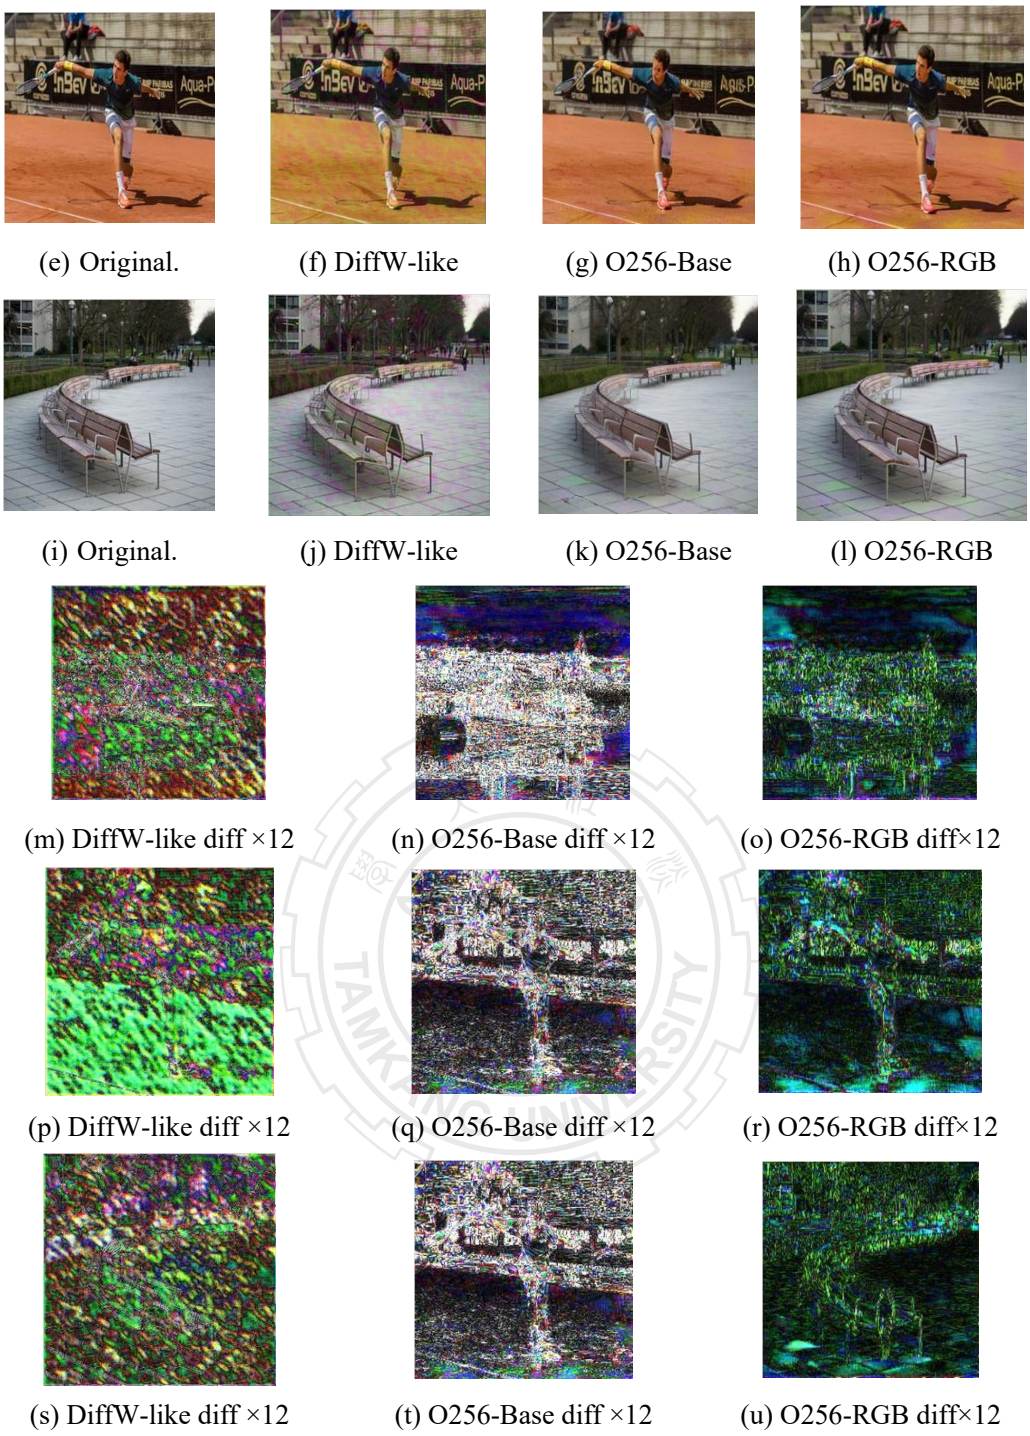
除了量化指標外，圖 12 進一步呈現 DiffW-like、O256-Base 與原始 O256-RGB 基準版本之定性影像比較，以及 RGB 修復前後的差異變化。每列為一組測試影像，依序呈現原始影像、DiffW-like 輸

出、O256-Base 輸出、原始 O256-RGB 基準版本輸出、O256-Base 與原始影像之差異圖，以及原始 O256-RGB 基準版本與原始影像之差異圖。差異圖為 RGB 絕對差異，並放大 12 倍以利視覺化觀察。需要注意的是，圖中 O256-RGB 代表早期 RGB 修復基準版本，主要用於說明 RGB 修復對影像品質的改善效果，並非最終校準設定之輸出結果。

由圖 12 可觀察到，DiffW-like 作為本文統一實驗協定下的比較基線，其輸出影像可輔助觀察不同方法在視覺品質上的差異。相較之下，O256-Base 的差異圖較明亮，表示其輸出影像與原始影像之間仍存在較明顯差異；經原始 RGB 修復後，O256-RGB 的差異圖整體變暗，代表輸出影像與原始影像的差異降低。此定性結果與表 4 中原始 O256-RGB 基準版本相較於 O256-Base 的 PSNR、SSIM 與 LPIPS 改善趨勢一致，說明 RGB 修復模組本身確實能有效改善輸出影像品質。



(a) Original. (b) DiffW-like (c) O256-Base (d) O256-RGB



(e) Original. (f) DiffW-like (g) O256-Base (h) O256-RGB

(i) Original. (j) DiffW-like (k) O256-Base (l) O256-RGB

(m) DiffW-like diff ×12 (n) O256-Base diff ×12 (o) O256-RGB diff×12

(p) DiffW-like diff ×12 (q) O256-Base diff ×12 (r) O256-RGB diff×12

(s) DiffW-like diff ×12 (t) O256-Base diff ×12 (u) O256-RGB diff×12

圖 12、原始 O256-RGB 基準版本之定性影像比較

然而，圖 12 僅呈現原始 O256-RGB 基準版本之定性結果，無法直接反映最終校準設定在訊息強健性上的改善。因此，圖 12 的

作用應定位為影像品質改善之視覺化輔助，而最終修訂設定對未受攻擊 BA、非幾何攻擊平均 BA 與最低 BA 的改善，仍以表 4 與表 5 的量化結果為主要依據。

4.3 非幾何攻擊強健性分析

在完成整體性能比較後，本節進一步分析不同設定於各類非幾何攻擊條件下的位元準確率表現。相較於前一節所呈現的未受攻擊 BA、非幾何攻擊平均 BA 與最低 BA，逐項攻擊結果能更清楚顯示模型在特定攻擊條件下的強項與弱點。由於前一節結果顯示原始 O256-RGB 基準版本的主要問題並非影像品質不足，而是最低 BA 明顯偏低，因此本節特別聚焦於 Dropout 攻擊下的最弱條件，以及最終修訂設定是否能改善此一弱點。

為避免表格過寬，表 6 使用縮寫表示各攻擊設定。其中，Dropout 表示 Paper_Dropout_r03；GB2、GB3、GB4 分別表示標準差為 2、3、4 的高斯模糊；GN-A 與 GN-V 分別表示兩組高斯雜訊設定，其中 GN-A 對應雜訊參數 0.3，GN-V 對應變異數 0.09；JPEG30、JPEG40、JPEG50 表示不同壓縮品質參數之 JPEG 壓縮；MF5 表示視窗大小為 5 的中值濾波；SP0.2 表示比例為 0.2 的椒鹽雜訊。表中數值單位皆為百分比；「未受攻擊 BA」表示未施加攻擊條件下之

位元準確率，不納入「非幾何攻擊平均 BA」的計算；「非幾何攻擊平均 BA」表示 11 種正式非幾何攻擊條件下的平均位元準確率，「最低 BA」則表示 11 種正式非幾何攻擊條件中最低的位元準確率。

表 6、非幾何攻擊下之位元準確率比較

攻擊類型／指標	DiffW-like	原始 O256-RGB 基準版本	最終校準 exp52	最終校準 exp53	exp54 補充驗證
未受攻擊 BA	100.00	95.81	99.99	99.85	99.94
Dropout	95.47	72.93	90.33	91.36	89.98
GB2	100.00	95.46	100.00	99.91	99.95
GB3	100.00	95.15	99.99	99.91	99.95
GB4	100.00	94.96	99.99	99.91	99.95
GN-A	97.82	75.60	98.07	97.12	96.33
GN-V	100.00	84.33	99.67	99.38	99.18
JPEG30	100.00	88.10	99.88	99.62	99.55
JPEG40	100.00	90.47	99.92	99.71	99.74
JPEG50	100.00	91.77	99.96	99.77	99.82
MF5	100.00	94.74	99.99	99.93	99.93
SP0.2	99.56	77.66	98.58	97.74	97.45
非幾何攻擊平均 BA	99.35	87.38	98.76	98.58	98.35
最低 BA	95.47	72.93	90.33	91.36	89.98

由表 6 可觀察到，DiffW-like 在正式非幾何攻擊集合下仍具有最高的整體強健性，其非幾何攻擊平均 BA 為 99.35%，最低 BA 為 95.47%。此結果表示 DiffW-like 在本文正式評估協定下對多數非幾何攻擊具有良好的訊息恢復能力。然而，如前一節所述，DiffW-like

的影像品質指標明顯低於本文後續修復設定，因此本文並不主張最終校準設定在所有強健性指標上全面超越 DiffW-like，而是將其定位為在影像品質、平均強健性與最弱攻擊條件下訊息恢復能力之間取得較穩定折衷的設定。

相較之下，原始 O256-RGB 基準版本雖能提升影像品質，但在多數非幾何攻擊下仍存在明顯訊息恢復不足。其中，Dropout 攻擊下的 BA 僅為 72.93%，同時也是該設定的最低 BA；GN-A、GN-V 與 SP0.2 亦分別只有 75.60%、84.33%與 77.66%。此結果顯示，早期 RGB 修復模組雖可降低輸出影像與原始影像之間的視覺差異，但其修復過程可能同時削弱部分對訊息解碼有用的浮水印訊號，尤其在 Dropout 與隨機雜訊類攻擊下更為明顯。

最終修訂階段所加入之 Dropout 感知式 RGB 修復訓練排程，主要即針對此弱點進行改善。由 exp52 與 exp53 可知，經解碼器感知式最終校準後，Dropout 攻擊下的 BA 分別提升至 90.33%與 91.36%，相較於原始 O256-RGB 基準版本的 72.93%，分別提升 17.40 與 18.43 個百分點。同時，兩組正式重跑的非幾何攻擊平均 BA 也分別達到 98.76%與 98.58%，顯示此修訂不只是改善單一攻擊條件，而是整體提高非幾何攻擊下的訊息恢復穩定性。

從各攻擊類型來看，最終校準設定在高斯模糊、JPEG 壓縮與中值濾波下幾乎皆維持接近 100%的 BA，代表修復後浮水印訊號對平滑化與壓縮類失真具有高度穩定性。在高斯雜訊與椒鹽雜訊下，exp52 與 exp53 雖略低於模糊與壓縮類攻擊，但仍明顯高於原始 O256-RGB 基準版本。例如 GN-A 由 75.60%提升至 98.07%與 97.12%，SP0.2 則由 77.66%提升至 98.58%與 97.74%。此結果顯示，最終校準設定不僅補強 Dropout 攻擊下的最低 BA，也同步改善隨機雜訊與椒鹽雜訊造成的訊息恢復下降問題。

此外，exp54 作為隨機種子 63 的額外補充驗證，其非幾何攻擊平均 BA 為 98.35%，顯示整體平均強健性仍維持高水準；然而，其 Dropout 攻擊下的 BA 為 89.98%，接近但未達 90%門檻，因此不列入嚴格通過之最終主結果。此結果說明，Dropout 攻擊仍是本文最終設定中最接近失效邊界的條件，也支持本節將 Dropout 視為最弱攻擊條件進行分析的必要性。

綜合而言，原始 O256-RGB 基準版本的主要限制在於 RGB 修復雖改善影像品質，卻未能充分保留最弱攻擊條件下的訊息可恢復性。本文最終修訂設定透過 Dropout 平衡式穩定化與解碼器感知式最終校準，使最低 BA 由 72.93%提升至 exp52 的 90.33%與 exp53

的 91.36%，並使非幾何攻擊平均 BA 維持於 98%以上。此結果支持本文之核心觀察：RGB 修復不應僅以影像品質為目標，而必須同時約束修復後影像在攻擊後仍保有可被訊息解碼器恢復的浮水印訊號。

4.4 消融實驗與方法設計分析

本節進一步分析本文方法在 RGB 修復流程中的設計演進。前述結果顯示，原始 O256-RGB 基準版本雖能有效改善影像品質，但其最低 BA 仍明顯不足，代表早期 RGB 修復流程在提升視覺品質時，仍可能削弱攻擊後可供訊息解碼器恢復的浮水印訊號。為便於後續表格呈現，本文將早期 RGB 修復流程依序記為階段 A、階段 B、階段 B+與階段 C，其中階段 C 即為原始 O256-RGB 基準版本。表 7 彙整早期 RGB 修復分階段消融實驗結果，用以觀察影像品質與訊息保留能力之間的折衷關係。

由表 7 可知，RGB 修復模組確實能顯著提升影像品質。相較於 O256-Base，階段 A 的 PSNR 由 24.70dB 提升至 36.92dB，SSIM 由 0.7018 提升至 0.9850，LPIPS 則由 0.0934 降低至 0.0176。然而，階段 A 的未受攻擊 BA、非幾何平均 BA 與最低 BA 皆明顯下降，分別僅為 88.75%、80.74%與 65.24%。此結果表示，若 RGB 修復

器過度偏向影像相似度或感知品質，可能同時削弱對訊息解碼有用的浮水印訊號。

表 7、早期 RGB 影像修復分階段消融實驗結果

設定	PSNR↑	SSIM↑	LPIPS↓	未受攻擊 BA↑	非幾何平均 BA↑	最低 BA↑
O256-Base	24.70	0.7018	0.0934	99.30%	87.33%	70.38%
階段 A	36.92	0.9850	0.0176	88.75%	80.74%	65.24%
階段 B	33.76	0.9678	0.0371	94.70%	86.03%	70.72%
階段 B+	33.24	0.9618	0.0422	95.49%	86.79%	72.26%
階段 C	32.90	0.9589	0.0461	95.81%	87.38%	72.93%

後續階段 B、B+與階段 C 透過調整修復強度與訓練設定，逐步恢復訊息保留能力。其中，階段 C 取得 PSNR 為 32.90dB、SSIM 為 0.9589、LPIPS 為 0.0461，並將未受攻擊 BA 提升至 95.81%、非幾何平均 BA 提升至 87.38%、最低 BA 提升至 72.93%。雖然階段 C 已較階段 A 更能兼顧影像品質與訊息保留，但最低 BA 仍明顯不足，因此後續需要進一步針對最弱攻擊條件加入 Dropout 感知式 RGB 修復訓練排程。

為說明最終修訂設定的形成過程，表 8 進一步整理階段 C 之

後的主要設計演進。此處重點並非重新設計 RGB 修復器架構，而是透過訓練協定與損失權重配置，使修復器在改善影像品質的同時，保留經 Dropout 攻擊後仍可被訊息解碼器恢復的浮水印訊號。

表 8、Dropout 感知式 RGB 修復訓練排程之設計演進

設計階段	對應實驗	目的	主要觀察
階段 C	原始 O256-RGB 基準版本	建立早期完整版本	影像品質提升，但最低 BA 僅 72.93%
Dropout 平衡式穩定化	exp40、exp41	提高最弱攻擊條件下的訊息保留能力	exp40 通過 90%門檻，exp41 接近但略低於門檻
解碼器感知式最終校準	exp52、exp53	約束未受攻擊與經 Dropout 攻擊後影像的訊息可恢復性	兩組正式重跑皆通過最低 BA90%門檻
額外隨機種子補充驗證	exp54	檢查不同隨機種子下的邊界情況	最低 BA 為 89.98%，不列入嚴格通過之最終主結果

由表 8 可知，最終修訂設定並非單純延長訓練步數，也不是重新設計 RGB 修復器架構，而是由早期 RGB 修復消融與後續 Dropout 攻擊診斷逐步形成。階段 C 已能在影像品質上明顯優於 O256-Base，但最低 BA 僅為 72.93%，顯示其在最弱攻擊條件下仍未能充分保留浮水印訊號。因此，後續修訂重點轉向修復器訓練協定，而不是再單純提高影像相似度。

Dropoup 平衡式穩定化的目的，是在 RGB 修復訓練中提高 Dropout 攻擊條件下的訊息保留壓力，使修復器不要在提升畫質時破壞攻擊後仍需保留的浮水印訊號。由 exp40 與 exp41 可知，此設計已能將最低BA由階段C的72.93%大幅提升至91.01%與89.94%。其中 exp41 雖接近 90%門檻但仍略低 0.06 個百分點，顯示單純進行Dropout平衡式穩定化仍可能在不同隨機種子下出現邊界不穩定情況。

為進一步降低此邊界風險，本文於最終修訂設定中加入解碼器感知式最終校準。此校準透過固定參數之訊息解碼器D_ϕ，約束未受攻擊影像與經 Dropout 攻擊後影像的訊息可恢復性，使 RGB 修復器不只學習恢復影像外觀，也同時考慮修復結果是否仍能被訊息解碼器正確讀取。由 exp52 與 exp53 可知，兩組從零開始完整訓練之正式重跑分別取得最低 BA 為 90.33%與 91.36%，並同時維持約 34dB 的 PSNR、0.9825 的 SSIM 與約 0.04 的 LPIPS。因此，本文將 exp52 與 exp53 作為最終主結果。

另一方面，exp54 額外使用隨機種子 63 進行補充驗證，其非幾何攻擊平均 BA 仍達 98.35%，代表整體平均強健性維持高水準；然而，其最低 BA 為 89.98%，接近但未達 90%門檻，因此不列入嚴

格通過之最終主結果。此結果並不推翻最終修訂設定的有效性，但提醒 Dropout 攻擊仍是本文方法中最接近失效邊界的條件，也說明後續若要進一步提升跨隨機種子的穩定性，仍可針對 Dropout 攻擊下的邊界情況進行加強。

綜合上述結果，早期 RGB 修復消融實驗說明影像品質與訊息保留能力之間存在明顯折衷；而 Dropout 感知式 RGB 修復訓練排程則進一步針對此折衷進行校準，使修復器不僅追求較佳視覺品質，也保留經攻擊後可由訊息解碼器恢復的浮水印訊號。此設計演進支持本文最終主張：RGB 修復模組若要用於強健浮水印任務，不能僅以影像相似度為訓練目標，而必須同時納入訊息可恢復性的約束。

4.5 計算成本與推論效率分析

本節進一步分析本文方法在訓練成本、完整準備成本與推論效率上的表現。由於本文最終修訂設定除了基礎模型訓練外，尚包含 RGB 修復配對資料產生與 RGB 修復器訓練，因此本節將成本分為「訓練成本可比性檢查」、「一次性完整準備成本」與「端到端推論時間」三部分討論。前者用於說明 DiffW-like 與本文最終校準設定在訓練成本比較上的限制；第二部分用於呈現本文最終校準設定建立一組可用模型所需的完整準備成本；第三部分則用於衡量模型部

署後，對測試影像產生含浮水印結果時的實際推論效率。

首先需要說明的是，DiffW-like 與本文最終校準設定的訓練成本不適合直接解讀為同等表現下的公平比較。DiffW-like formal 20k 雖具有較高的非幾何攻擊強健性，但其影像品質明顯低於本文最終校準設定；相反地，DiffW-like 長訓練至 60k 步後雖可取得較高 PSNR，但最低 BA 明顯下降。因此，本文不將 DiffW-like formal 顯低於本文最終校準設定；相反地，DiffW-like 長訓練至 60k 步後雖可取得較高 PSNR，但最低 BA 明顯下降。因此，本文不將 DiffW-like formal 20k 的訓練時間視為達成同等影像品質與強健性折衷所需的成本，而僅將其作為本地比較基準之訓練成本參考。表 9 彙整 DiffW-like 不同訓練設定與本文最終校準設定之表現及成本定位。

表 9 的重點不是宣稱本文最終校準設定在訓練成本上優於 DiffW-like，而是說明兩者目前沒有同等表現下的直接成本對照。DiffW-like formal 20k 的完整訓練時間較短，但其 PSNR 僅為 26.4236dB，無法代表達到本文最終校準設定影像品質所需的成本；DiffW-like60k 雖將 PSNR 提升至 37.4562dB，但最低 BA 下降至 68.18%，亦無法視為同等強健性條件下的比較。因此，本文對訓練成本採取保守解讀：DiffW-like 訓練成本可作為基準方法成本參考，

但不作為同等表現下的成本勝負判斷。

表 9、DiffW-like 與最終校準設定之訓練成本可比性檢查

設定	訓練／準備時間	PSNR↑	非幾何平均 BA↑	最低 BA↑	定位
DiffW-like formal 20k	02:25:31	26.4236	99.35%	95.47%	強健性高，但影像品質明顯低於本文最終設定
DiffW-like 35k	04:15:46	28.7506	94.76%	70.00%	延長訓練後影像品質提升，但最低 BA 明顯下降
DiffW-like 60k	07:18:07	37.4562	91.91%	68.18%	PSNR 較高，但無法維持最弱攻擊條件下的訊息恢復能力
最終校準設定平均（exp52/exp53）	04:50:34	33.9951	98.67%	90.85%	本文最終主結果，取得影像品質與最低 BA 之折衷

接著，表 10 彙整本文最終校準設定於不同隨機種子下的完整準備成本。本文最終校準設定的完整準備成本包含三部分：基礎模型訓練、RGB 修復配對資料產生，以及 RGB 修復器訓練。其中，基礎模型訓練時間包含 65,000 步的基礎端訓練流程；配對資料產生時間為產生 RGB 修復器訓練所需(x_w, x_c)配對資料的時間；RGB 修復器訓練時間則包含早期 RGB 修復流程、Dropout 平衡式穩定化與解碼器感知式最終校準等修復器訓練階段。表中時間依據訓練紀錄中的實際執行時間彙整，包含訓練過程中的紀錄與模型權重儲

存開銷，但不包含正式攻擊評估、BA、PSNR、SSIM 與 LPIPS 等後續評估時間，其中，exp52 與 exp53 對應本文最終主結果；exp54 則為相同最終校準設定下之額外隨機種子補充驗證，因此於表 10 與表 11 中僅作為成本與效率之補充參考。

由表 10 可知，本文最終校準設定的完整準備成本約為 4 小時 47 分至 4 小時 52 分。其中，主要時間來自基礎模型訓練；RGB 修復配對資料產生約需 15 至 16 分鐘，RGB 修復器訓練約需 46 至 47 分鐘。此結果表示，本文最終設定相較於僅訓練單一基礎模型，確實需要額外的一次性準備成本。然而，此成本主要發生於模型訓練與準備階段，並不會在每次正式推論時重複發生。

表 10、本文最終校準設定之完整準備成本

實驗	隨機種子	基礎模型訓練	配對資料產生	RGB 修復器訓練	完整準備成本
exp52	62	03:47:16	00:15:39	00:46:30	04:49:25
exp53	61	03:48:32	00:16:02	00:47:09	04:51:42
exp54	63	03:45:28	00:15:25	00:46:21	04:47:14

因此，本文方法在訓練端的定位並非「最低訓練成本」，而是在可接受的一次性準備成本下，透過 RGB 修復與解碼器感知式最

終校準，取得較佳影像品質、較高非幾何攻擊平均 BA，以及較穩定的最低 BA。換言之，訓練成本應與前述影像品質與強健性結果一併解讀，而不應單獨視為本文方法優於或劣於基準方法的唯一依據。

最後，表 11 整理不同方法於 locked finaltest1000 上的端到端推論時間。此測時包含資料讀取、模型推論、含浮水印影像產生與輸出寫入，但不包含 PSNR、SSIM、LPIPS、BA 與攻擊評估等後續指標計算。相較於訓練成本，端到端推論時間的協定較為一致，皆是在同一批 1000 張正式測試影像上產生輸出結果，因此可作為推論效率比較的主要依據。

由表 11 可知，DiffW-like 於 1000 張測試影像上的端到端推論時間為 399.85 秒，平均每張影像約需 399.85 毫秒。相較之下，本文最終校準設定在 exp52 與 exp53 中，處理 1000 張影像的總時間分別為 164.96 秒與 165.77 秒，對應每張影像耗時 164.96 毫秒與 165.77 毫秒，加速倍率分別為 DiffW-like 的 2.42 倍與 2.41 倍。此結果顯示，雖然本文方法在訓練準備階段需要額外的 RGB 修復相關成本，但在部署推論階段仍可維持明顯優於 DiffW-like 的端到端產生效率。

表 11、locked finaltest1000 上之端到端推論時間比較

方法／設定	影像數量	總時間	每張影像耗時	每秒影像數	相對 DiffW-like 加速
DiffW-like	1000	00:06:39.85	399.85ms	2.50	1.00×
最終校準設定（exp52）	1000	00:02:44.96	164.96ms	6.06	2.42×
最終校準設定（exp53）	1000	00:02:45.77	165.77ms	6.03	2.41×
額外補充驗證（exp54）	1000	00:02:40.35	160.35ms	6.24	2.49×

需要注意的是，本文目前未補測最終校準設定的純計算推論時間，因此不以純計算測時作為最終設定的正式結論。舊版 O256-RGB 的純計算測時僅能作為歷史基準或背景參考，不能直接代表最終校準設定。為避免過度宣稱，本節僅根據已完成的端到端推論測時說明：在包含資料讀取與輸出寫入的實際推論流程下，本文最終校準設定仍可維持約 2.4 倍於 DiffW-like 的推論速度。

綜合而言，本文方法並非主張訓練成本全面低於 DiffW-like，而是在可接受的一次性準備成本下，取得較佳影像品質、較高非幾何攻擊平均 BA 與較穩定的最低 BA，並於正式推論階段維持約 2.4 倍於 DiffW-like 的端到端推論效率。

4.6 本章小結

本章針對本文所提出之 O256 系列方法進行實驗結果與分析，並與 DiffW-like 本地比較基線進行對照。實驗結果顯示，O256-Base 雖能在未受攻擊條件下維持高位元準確率，但其影像品質與最低 BA 仍不足；原始 O256-RGB 基準版本則可透過 RGB 修復模組大幅改善影像品質，使 PSNR 由 O256-Base 的 24.7037dB 提升至 32.9034dB，SSIM 由 0.7018 提升至 0.9589，LPIPS 由 0.0934 降至 0.0461。然而，原始 O256-RGB 基準版本的最低 BA 僅為 72.93%，顯示早期 RGB 修復流程雖能提升視覺品質，仍可能削弱最弱攻擊條件下的訊息可恢復性。

針對上述問題，本文於最終修訂階段加入 Dropout 感知式 RGB 修復訓練排程。此排程並未改變 RGB 修復器架構，而是透過 Dropout 平衡式穩定化與解碼器感知式最終校準，使修復器在提升影像品質的同時，保留經 Dropout 攻擊後仍可被訊息解碼器恢復的浮水印訊號。實驗結果顯示，exp52 與 exp53 兩組從零開始完整訓練之正式重跑皆通過最低 BA 為 90%之門檻。其中，exp52 取得 PSNR 為 34.0379dB、SSIM 為 0.9825、LPIPS 為 0.0451、未受攻擊 BA 為 99.99%、非幾何攻擊平均 BA 為 98.76%，以及最低 BA 為

90.33%；exp53 則取得 PSNR 為 33.9522dB、SSIM 為 0.9825、LPIPS 為 0.0400、未受攻擊 BA 為 99.85%、非幾何攻擊平均 BA 為 98.58%，以及最低 BA 為 91.36%。相較於原始 O256-RGB 基準版本，最終校準設定平均使最低 BA 提升約 17.92 個百分點，顯示其主要改善效果集中於原始 RGB 修復流程最不足的最弱攻擊條件。

在逐項非幾何攻擊分析中，Dropout 攻擊為本文方法最接近失效邊界的攻擊條件。原始 O256-RGB 基準版本在 Dropout 攻擊下的最低 BA 僅為 72.93%，而經最終校準後，exp52 與 exp53 分別提升至 90.33%與 91.36%。此外，高斯模糊、JPEG 壓縮與中值濾波等攻擊下的 BA 亦多數維持接近 100%，高斯雜訊與椒鹽雜訊下的表現也相較原始 O256-RGB 基準版本明顯提升。另一方面，exp54 作為隨機種子 63 的額外補充驗證，其非幾何攻擊平均 BA 仍達 98.35%，但最低 BA 為 89.98%，接近但未達 90%門檻，因此不列入嚴格通過之最終主結果。此結果提醒，Dropout 攻擊仍是後續可進一步強化的主要方向。

消融實驗與方法設計分析進一步說明，本文方法的改進並非單純來自增加訓練步數或重新設計 RGB 修復器架構。早期 RGB 修復分階段消融結果顯示，若修復器過度偏向影像相似度或感知品質，

雖可大幅提升 PSNR 與 SSIM，卻可能明顯降低未受攻擊 BA、非幾何攻擊平均 BA 與最低 BA。因此，RGB 修復模組若要應用於強健浮水印任務，不能只以影像品質為目標，而必須同時納入訊息可恢復性的約束。Dropout 平衡式穩定化用於提高最弱攻擊條件下的訊息保留壓力；解碼器感知式最終校準則進一步利用固定參數之訊息解碼器，約束未受攻擊影像與經 Dropout 攻擊後影像的訊息可恢復性。兩者共同形成本文最終修訂設定的核心。

在計算成本方面，本文最終校準設定需要額外的一次性完整準備成本，主要包含基礎模型訓練、RGB 修復配對資料產生與 RGB 修復器訓練。若與 DiffW-like 之本地比較基線相比，本文最終設定並不主張在一次性訓練準備成本上較低；相反地，額外的修復與校準流程會增加完整準備時間。然而，在正式推論階段，本文最終校準設定於 locked finaltest1000 上仍可維持約 2.4 倍於 DiffW-like 的端到端推論速度。由此可知，本文方法的成本定位並非追求最低訓練成本，而是在可接受的一次性準備成本下，取得較佳影像品質、較高非幾何攻擊平均 BA，以及較穩定的最低 BA 表現。

整體而言，本章實驗結果支持本文之主要觀察：潛在空間浮水印嵌入方法若直接經由 VAE 解碼回到 RGB 影像，容易在影像品質

與訊息保留能力之間產生折衷；RGB 修復模組能有效改善影像品質，但若缺乏訊息導向約束，仍可能破壞攻擊後可恢復的浮水印訊號。本文最終修訂設定透過 Dropout 感知式 RGB 修復訓練排程，將影像修復與訊息可恢復性共同納入訓練考量，使方法在影像品質、非幾何攻擊平均強健性與最弱攻擊條件下的可靠性之間取得較穩定的折衷。

第五章 結論與未來展望

本章針對本文研究內容與實驗結果進行總結，並說明目前方法之研究限制與未來可延伸方向。本文以潛在擴散模型為基礎，探討如何在 Stable Diffusion 2.1 VAE 潛在空間中嵌入 32 位元浮水印訊息，並透過 RGB 影像修復模組改善輸出影像與原始影像之間的品質差異。根據第四章實驗結果，本文方法的核心問題並非僅在於提高浮水印可恢復性，而是如何在影像品質、訊息恢復能力、非幾何攻擊強健性與推論效率之間取得較穩定的折衷。

5.1 研究結論

本文提出一套以潛在擴散模型為基礎之影像浮水印方法，目標是在潛在空間中嵌入 32 位元二進位浮水印訊息，並在常見非幾何影像處理後仍能恢復原始訊息。本文方法以固定參數之 Stable Diffusion 2.1 VAE 建立潛在空間與 RGB 影像空間之間的轉換流程，並透過潛在空間 U-Net 浮水印編碼器與訊息解碼器完成訊息嵌入與恢復。此外，本文採用位元平面訊息表示作為訊息條件表示，使每一個訊息位元能以空間位元平面的形式參與特徵建構，以提升位元層級識別性的保留能力與訊息恢復穩定性。

實驗結果顯示，O256-Base 能在未受攻擊條件下維持高位元準確率，證明本文所設計之潛在空間浮水印基礎模型能有效建立訊息嵌入與恢復通道。然而，僅依賴潛在空間浮水印嵌入時，輸出影像仍受到固定參數 VAE 重建與潛在表示修改的限制，使 PSNR 與 SSIM 表現較低。此結果說明，潛在空間浮水印雖具備訊息嵌入能力，但仍需要額外機制改善 RGB 輸出影像與原始影像之間的品質差異。

為改善上述問題，本文進一步加入 RGB 影像修復模組。原始 O256-RGB 基準版本以 O256-Base 輸出影像與原始影像作為輸入，並於 RGB 空間中學習殘差修正量，以產生修復後含浮水印影像。第四章結果顯示，原始 O256-RGB 基準版本相較 O256-Base 能大幅提升影像品質，使 PSNR 由 24.7037dB 提升至 32.9034dB，SSIM 由 0.7018 提升至 0.9589，LPIPS 由 0.0934 降至 0.0461。此結果證明 RGB 影像修復模組能有效降低輸出影像與原始影像之間的品質差異。

然而，原始 O256-RGB 基準版本雖能改善影像品質，其最低 BA 僅為 72.93%，顯示早期 RGB 修復流程仍可能削弱攻擊後可供訊息解碼器恢復的浮水印訊號。換言之，RGB 修復若僅偏向影像相

似度或感知品質，可能使輸出影像更接近原始影像，但同時降低最弱攻擊條件下的訊息可恢復性。因此，本文最終修訂階段進一步加入 Dropout 感知式 RGB 修復訓練排程，使 RGB 修復器在改善影像品質的同時，也能保留經 Dropout 攻擊後仍可被訊息解碼器恢復的浮水印訊號。

本文最終修訂設定並未改變 RGB 影像修復模組的資料流、前向公式或模型架構，而是透過 Dropout 平衡式穩定化與解碼器感知式最終校準調整訓練協定與損失權重配置。Dropout 平衡式穩定化用於提高最弱攻擊條件下的訊息保留壓力；解碼器感知式最終校準則利用固定參數之訊息解碼器D_ϕ，約束未受攻擊影像與經 Dropout 攻擊後影像的訊息可恢復性。第四章實驗結果顯示，exp52 與 exp53 兩組從零開始完整訓練之正式重跑皆通過最低 BA 為 90%之門檻。其中，exp52 取得 PSNR 為 34.0379dB、SSIM 為 0.9825、LPIPS 為 0.0451、未受攻擊 BA 為 99.99%、非幾何攻擊平均 BA 為 98.76%，以及最低 BA 為 90.33%；exp53 則取得 PSNR 為 33.9522dB、SSIM 為 0.9825、LPIPS 為 0.0400、未受攻擊 BA 為 99.85%、非幾何攻擊平均 BA 為 98.58%，以及最低 BA 為 91.36%。

相較於原始 O256-RGB 基準版本，最終校準設定平均使 PSNR

提升約 1.0917 dB，SSIM 提升約 0.0236，LPIPS 降低約 0.0035，未受攻擊 BA 提升約 4.11 個百分點，非幾何攻擊平均 BA 提升約 11.29 個百分點，最低 BA 則由 72.93%提升至平均 90.85%，提升幅度達 17.92 個百分點。此結果顯示，最終修訂設定的主要貢獻不只是改善平均強健性，而是針對原始 RGB 修復流程最不足的最弱攻擊條件進行補強。

在計算成本方面，本文最終校準設定需要額外的一次性完整準備成本，主要包含基礎模型訓練、RGB 修復配對資料產生與 RGB 修復器訓練。若與 DiffW-like 之本地比較基線相比，本文最終設定並不主張在一次性訓練準備成本上較低；相反地，額外的修復與校準流程會增加完整準備時間。然而，在正式推論階段，本文最終校準設定於 locked finaltest1000 上仍可維持約 2.4 倍於 DiffW-like 的端到端推論速度。綜合而言，本文方法的主要貢獻在於針對潛在空間浮水印的影像品質與最弱攻擊條件下訊息恢復不足問題提出修正方式，使最終校準設定能在較高影像品質、較高非幾何攻擊平均 BA、較穩定最低 BA 與可接受推論效率之間取得較佳折衷。

5.2 研究限制

雖然本文方法在影像品質改善與非幾何攻擊強健性方面展現

一定效果，但仍存在若干限制。首先，本文正式強健性評估主要聚焦於非幾何攻擊，例如 Dropout、高斯模糊、高斯雜訊、JPEG 壓縮、中值濾波與椒鹽雜訊等常見影像處理。這些攻擊能反映影像在遮蔽、壓縮、雜訊、模糊與局部像素破壞下的訊息保留能力，但尚未完整涵蓋裁切、旋轉、縮放、透視變換等幾何攻擊，也尚未完整評估影像編輯或生成式影像編輯類型攻擊。因此，本文結果不應被解讀為已完整驗證模型對所有影像變換或語意層級編輯攻擊之強健性。

其次，本文正式訓練與主要評估仍以 COCO 資料集與 locked finaltest1000 為核心，其結論主要支持模型於目前資料分布、影像解析度、訊息長度與測試協定下的有效性。本文尚未進行完整正式的跨資料集泛化與跨模型遷移實驗。若將方法遷移至其他大規模資料集、不同影像分布、不同 VAE、不同潛在擴散模型骨幹、不同解析度或不同訊息長度，其影像品質、訊息恢復能力與攻擊強健性仍可能需要重新訓練與調整。

第三，本文所使用之 DiffW-like 是在本文統一實驗協定下重新實作、重新訓練並重新評估之比較基線，而非 DiffW 原論文官方模型檢查點或官方完整重現結果。此設定能使 DiffW-like 與本文方法使用相同資料集、解析度、訊息長度與攻擊評估流程，提升比較協

定的一致性；然而，其結果仍應理解為本文實驗環境下的 DiffW-like 比較基線，而非原始 DiffW 論文結果的直接重現。

第四，Dropout 攻擊仍是本文方法最接近失效邊界的攻擊條件。第四章結果顯示，exp52 與 exp53 雖皆通過最低 BA 為 90%之門檻，但 exp54 於隨機種子 63 下的最低 BA 為 89.98%，接近但未達 90%門檻，因此不列入嚴格通過之最終主結果。此結果表示，本文最終修訂設定已能大幅改善原始 O256-RGB 基準版本在 Dropout 攻擊下的不足，但不同隨機種子下仍可能出現接近門檻的邊界情況。若應用情境要求更高的最低 BA 安全邊際，仍需進一步提升 Dropout 攻擊下的跨隨機種子穩定性。

最後，本文最終校準設定雖能改善影像品質與最弱攻擊條件下的訊息恢復能力，但仍需要額外的一次性完整準備成本。相較於僅訓練基礎模型或單一比較基線，本文方法需包含基礎模型訓練、RGB 修復配對資料產生與 RGB 修復器訓練。因此，本文方法較適合需要改善輸出影像品質且可接受額外準備成本的情境；若應用場景最重視最低訓練成本、跨攻擊全面強健性或最高安全邊際，則仍需根據需求進一步調整模型設計與訓練策略。

5.3 未來展望

未來研究可從數個方向延伸本文方法。首先，可將正式評估範圍擴展至更完整的浮水印強健性基準評估。本文目前主要聚焦於非幾何攻擊，而近年相關研究已開始強調更廣泛且更接近真實應用的攻擊情境，例如幾何變換、影像編輯、生成式影像編輯與多步驟複合攻擊等。未來可參考 WAVES[30]與 W-Bench[31]的評估設計，將本文方法納入更完整的基準測試，以分析其在不同攻擊類型下的穩定性與失效模式。

其次，可進一步提升模型對幾何攻擊與影像編輯攻擊的強健性。由於裁切、旋轉、縮放與透視變換會改變影像空間對齊關係，而指令導向編輯、局部編輯、全域編輯與影像再生成則可能改變影像語意內容或局部結構，因此這些攻擊對目前方法而言仍具有挑戰。未來可考慮加入幾何資料增強、對齊感知解碼器、空間同步模組或編輯感知訓練，以改善模型在更複雜攻擊情境下的訊息恢復能力。

第三，可進一步研究 Dropout 攻擊下的邊界穩定性。第四章結果顯示，Dropout 攻擊是本文方法中最接近最低 BA 門檻的攻擊條件，且 exp54 仍出現接近但未達 90%門檻的情況。未來可針對不同 Dropout 比例、不同遮蔽型態、不同隨機種子與不同攻擊組合進行

更完整分析，並進一步調整 Dropout 感知式 RGB 修復訓練排程，使最低 BA 在不同訓練重跑下保有更高安全邊際。

第四，可進一步研究 RGB 影像修復模組與訊息保留之間的平衡。本文結果顯示，若 RGB 影像修復過度追求影像重建品質，會降低訊息恢復能力；若加入訊息保留導向與攻擊條件導向訓練，則能在影像品質與 BA 之間取得較佳折衷。未來可探索更精細的損失權重設計、感知損失、頻率感知損失或自適應修復策略，使 RGB 影像修復模組能根據影像內容與浮水印強度自動調整修復幅度，進一步提升影像品質與訊息可恢復性之間的穩定性。

最後，未來亦可進行跨資料集、跨模型與效率方面的延伸分析。除了將模型測試於不同影像資料集與不同影像分布外，也可分析本文方法是否能遷移至不同 VAE、不同潛在擴散模型骨幹或不同解析度設定。同時，本文最終校準設定雖然在正式推論階段之端到端推論速度仍高於 DiffW-like，但其仍需要額外的修復配對資料產生與 RGB 影像修復訓練。未來可考慮更有效率的修復訓練流程、輕量化蒸餾或聯合訓練策略，以降低完整準備成本，並提升方法在實際應用情境中的可部署性。

參考文獻

[1] J. Ho, A. Jain, and P. Abbeel, "Denoising diffusion probabilistic models," *Advances in neural information processing systems,* vol. 33, pp. 6840–6851, 2020.

[2] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer, "High-resolution image synthesis with latent diffusion models," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2022, pp. 10684–10695.

[3] X. Zhao *et al.*, "Invisible image watermarks are provably removable using generative AI," *Advances in neural information processing systems,* vol. 37, pp. 8643–8672, 2024.

[4] H. Hur, M. Kang, S. Seo, and J.-U. Hou, "Latent diffusion models for image watermarking: A review of recent trends and future directions," *Electronics,* vol. 14, no. 1, p. 25, 2024.

[5] L. Zhang, X. Liu, A. V. Martin, C. X. Bearfield, Y. Brun, and H. Guan, "Attack-resilient image watermarking using stable diffusion," *Advances in Neural Information Processing Systems,* vol. 37, pp. 38480–38507, 2024.

[6] T. Luo *et al.*, "DiffW: Multi-Encoder Based on Conditional Diffusion Model for Robust Image Watermarking," *IEEE Transactions on Multimedia,* vol. 28, pp. 837–852, 2025.

[7] Y. Song and S. Ermon, "Generative modeling by estimating gradients of the data distribution," *Advances in neural information processing systems,* vol. 32, 2019.

[8] J. Song, C. Meng, and S. Ermon, "Denoising diffusion implicit models," *arXiv preprint arXiv:2010.02502,* 2020.

[9] Y. Song, J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon, and B. Poole, "Score-based generative modeling through stochastic differential equations," *arXiv preprint arXiv:2011.13456,* 2020.

[10] P. Dhariwal and A. Nichol, "Diffusion Models Beat GANs

on image synthesis," *Advances in neural information processing systems,* vol. 34, pp. 8780–8794, 2021.

[11] Y. Wen, J. Kirchenbauer, J. Geiping, and T. Goldstein, "Tree-rings watermarks: Invisible fingerprints for diffusion images," *Advances in Neural Information Processing Systems,* vol. 36, pp. 58047–58063, 2023.

[12] A. Varlamov, D. Diatlova, and E. Spirin, "Metr: Image watermarking with large number of unique messages," *arXiv preprint arXiv:2408.08340,* 2024.

[13] Z. Yang, K. Zeng, K. Chen, H. Fang, W. Zhang, and N. Yu, "Gaussian shading: Provable performance-lossless image watermarking for diffusion models," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024, pp. 12162–12171.

[14] P. Fernandez, G. Couairon, H. Jégou, M. Douze, and T. Furon, "The stable signature: Rooting watermarks in latent diffusion models," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2023, pp. 22466–22477.

[15] C. Kim, K. Min, M. Patel, S. Cheng, and Y. Yang, "Wouaf: Weight modulation for user attribution and fingerprinting in text-to-image diffusion models," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024, pp. 8974–8983.

[16] Z. Ma, G. Jia, B. Qi, and B. Zhou, "Safe-sd: Safe and traceable stable diffusion with text prompt trigger for invisible generative watermarking," in *Proceedings of the 32nd ACM International Conference on Multimedia*, 2024, pp. 7113–7122.

[17] D. Lin, Y. Li, B. Tondi, K. Lin, B. Li, and M. Barni, "An Efficient Watermarking Method for Latent Diffusion Models via Low-Rank Adaptation and Dynamic Loss Weighting," *arXiv preprint arXiv:2410.20202,* 2024.

[18] H. Ci, Y. Song, P. Yang, J. Xie, and M. Z. Shou, "WMAdapter: Adding watermark control to latent diffusion models," *arXiv preprint arXiv:2406.08337,* 2024.

[19] Z. Meng, B. Peng, and J. Dong, "Latent watermark: Inject and detect watermarks in latent diffusion space," *IEEE Transactions on Multimedia,* vol. 27, pp. 3399–3410, 2025.

[20] H. Wu, X. Lin, and G. Tan, "Spread spectrum image watermarking through latent diffusion model," *Entropy,* vol. 27, no. 4, p. 428, 2025.

[21] R. Min, S. Li, H. Chen, and M. Cheng, "A watermark-conditioned diffusion model for ip protection," in *European Conference on Computer Vision*, 2024: Springer, pp. 104–120.

[22] Y. Hu, Z. Jiang, M. Guo, and N. Gong, "Stable signature is unstable: Removing image watermark from diffusion models," *arXiv preprint arXiv:2405.07145,* 2024.

[23] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 770–778.

[24] K. Zhang, W. Zuo, Y. Chen, D. Meng, and L. Zhang, "Beyond a gaussian denoiser: Residual learning of deep cnn for image denoising," *IEEE transactions on image processing,* vol. 26, no. 7, pp. 3142–3155, 2017.

[25] J. Zhu, R. Kaplan, J. Johnson, and L. Fei-Fei, "HiDDeN: Hiding Data with Deep Networks," in *Proceedings of the European conference on computer vision (ECCV)*, 2018, pp. 657–672.

[26] M. Tancik, B. Mildenhall, and R. Ng, "StegaStamp: Invisible Hyperlinks in Physical Photographs," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2020, pp. 2117–2126.

[27] T.-Y. Lin *et al.*, "Microsoft COCO: Common objects in context," in *European conference on computer vision*, 2014: Springer, pp. 740–755.

[28] Z. Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli, "Image quality assessment: from error visibility to structural similarity," *IEEE transactions on image processing,* vol. 13, no. 4, pp. 600–612,

2004.

[29] R. Zhang, P. Isola, A. A. Efros, E. Shechtman, and O. Wang, "The unreasonable effectiveness of deep features as a perceptual metric," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2018, pp. 586–595.

[30] B. An *et al.*, "WAVES: Benchmarking the robustness of image watermarks," *arXiv preprint arXiv:2401.08573,* 2024.

[31] S. Lu, Z. Zhou, J. Lu, Y. Zhu, and A. Kong, "Robust watermarking using generative priors against image editing: From benchmarking to advances," in *International Conference on Learning Representations*, 2025, vol. 2025

TAMKANG UNIVERSITY